
LoHoVLA: 用于长时间跨度具体任务的统一视觉-语言-动作模型

Yi Yang

Fudan University
21307130076@m.fudan.edu.cn

Jiaxuan Sun

ShanghaiTech University
sunjx2022@shanghaitech.edu.cn

Siqi Kou

Shanghai Jiao Tong University
happy-karry@sjtu.edu.cn

Yihan Wang

Fudan University
23301170011@m.fudan.edu.cn

Zhijie Deng*

Shanghai Jiao Tong University
zhijied@sjtu.edu.cn

Abstract

现实世界中的具身代理面临长远任务，这些任务以需要多步骤解决方案的高阶目标为特征，超越了单一动作。成功完成这些任务需要高阶任务规划（即将目标分解为子任务）和低阶运动控制（即生成精确的机器人动作）。虽然现有的视觉语言动作（VLA）模型和分层架构在具身任务中展示了潜力，但前者在规划方面往往黯然失色，后者可能因协调问题而受到影响，两者均影响表现。我们引入了一种新的统一 VLA 框架，用于长远任务，称为 LoHoVLA，以克服这些限制。LoHoVLA 利用一个大型预训练的视觉语言模型（VLM）作为基础，同时生成语言和动作标记，分别用于子任务生成和机器人动作预测。这种共享表示促进了跨任务的更好泛化。此外，LoHoVLA 采用了一种分层闭环控制机制，以减轻源自高阶规划和低阶控制的误差。为了训练 LoHoVLA，我们引入了 LoHoSet，这是一个基于 Ravens 模拟器构建的数据集，包含 20 个长远任务，每个任务包含 1000 个由视觉观测、语言目标、子任务和机器人动作组成的专家演示。实验结果表明，LoHoVLA 在 Ravens 模拟器中的长远具身任务上明显优于分层和标准 VLA 方法。这些发现强调了统一架构在推进可泛化具身智能方面的潜力。

1 引言

在现实世界中运行的实体代理需要处理长期的、可组合的和动态变化的任务 [30, 14, 41, 45]。与短期任务不同 [47, 21, 49, 38, 55, 22]，长期任务涉及无法通过单一行动完成的高层次目标。代理必须进行推理、执行移动，并适应环境中的失败或变化。这需要高层次的任务规划和低层次的运动控制，前者将整体目标分解为原子任务，后者生成准确的机器人动作以供执行。

视觉语言动作（VLA）模型已成为具身智能体的主导范式 [7, 24, 39]。它们通常使用大规模预训练的视觉语言模型（VLMs）作为骨干，并在机器人演示上进行微调，以将视觉和语言输入映射到可执行的机器人动作。尽管 VLA 模型能够有效提取观察和指令中的关键信息，但它们在有效规划和推理方面表现不足，导致在长时间任务上的性能不佳。

对长时间视角的体现任务的开创性研究通常采用分层架构 [52, 46, 1, 28, 50, 19]，包括一个基于 VLM 的高层规划器用于推理子任务指令，以及一个基于 VLA 的低层控制器用于将这

*Corresponding author.

些指令转化为机器人动作。虽然这种模块化结构提供了灵活性，但它常常导致次优的协调和有限的泛化能力 [20, 51]。这些限制强调了需要一种统一的、端到端的架构，将高层和低层推理结合在一个框架中。

为了弥合这一差距，我们引入 LoHoVLA，这是一种用于长时间水平化身任务的统一视觉-语言-动作模型，该模型同时整合了高层次的任务规划和低层次的运动控制。LoHoVLA 首先从输入观察和指定的高层次目标中推断出语言子任务，然后将推断出的子任务用作动作预测的上下文指导。机器人执行预测的动作以与环境进行交互和修改。随后捕获新的观察以推断下一个子任务和随后的动作。

我们构建了基于大规模预训练的视觉语言模型的 LoHoVLA，以利用其广泛的世界知识和推理能力 [8, 26]。我们增强了原有的语言头，以生成语言子任务和离散动作标记。这个共享的骨干网络使得在规划和控制方面能够学习通用的表征。为了进一步增强鲁棒性，我们引入了一种分层闭环控制机制：如果子任务的执行失败次数超过预定义的阈值，系统将重新计划子任务；否则，只基于新的环境状态更新动作。考虑到缺乏注释有细粒度子任务和动作的长时间跨度的示范，我们合成了数据集 LoHoSet 来训练 LoHoVLA。具体而言，LoHoSet 是基于 Ravens 机器人模拟器开发的，包含 20 个长时间跨度的具身任务。每个任务包括 1,000 个专家示范，包含视觉观测、语言目标、子任务和动作。在数据集上训练的 LoHoVLA 可以在已知和未知任务上显著超越分层基线和普通的视觉语言动作基线，显示出强大的推理和规划能力以及强大的泛化能力。这些发现强调了统一架构在现实世界具身智能中的潜力。

2 相关工作

2.1 视觉-语言-动作模型

视觉语言行为 (VLA) 模型通过连接感知、语言理解和控制，已成为机器人学习的一个核心范式。这些模型通常重新利用在互联网规模数据集上预训练的大规模视觉语言模型 (VLMs) [2, 16, 10, 23] 用于下游的机器人任务。此类预训练的 VLMs 提供丰富的语义先验和跨模态的强泛化能力，使其成为视觉运动策略的理想基础。最近的研究 [13, 24, 34] 微调这些基础，在机器人演示数据集上将图像和语言输入映射到运动动作，在新物体、指令和环境展示出令人鼓舞的泛化结果。

尽管取得了这些进展，大多数现有的 VLA 框架在进行多步推理或结构化任务分解的能力上仍然有限，而这些能力对于执行复杂或长周期任务至关重要。为了解决这个问题，一些方法引入外部规划器 [46, 15, 54] 或使用行动专家 [44] 来处理子任务规划，尽管这种模块化通常会引发协调开销并降低系统的鲁棒性。此外，虽然预训练的 VLMs 提供了强大的基础能力，但由于视觉语言预训练目标与机器人控制的细粒度需求之间的不匹配，它们整合到控制管道中仍然是一个挑战。我们的研究通过探索支持结构化推理和低级控制的架构设计来增强 VLA 模型，为日益增长的改善努力做出了贡献。

2.2 长视距具身任务规划

体态智能体在执行长时间任务时，需要具备高级规划能力，以便将高层次目标分解为连贯的子任务序列。最近的方法 [1, 4, 9, 11, 12, 18, 25, 27, 33, 37] 利用大型语言模型 (LLM) 来增强此类规划过程。这些方法通常使用 LLM 根据自然语言指令生成结构化规划，然后由专门的低级控制器执行。为了提高适应性，一些框架 [9, 12, 33, 37] 引入了重规划机制，使智能体能够通过调整策略来应对环境变化，从而增强在各种任务和环境中的鲁棒性和泛化能力。除了文本规划外，越来越多的人对将链式思维 (CoT) 推理 [42] 整合到体态系统中产生兴趣。这一范式 [53, 48, 43] 涉及生成中间推理步骤，以弥合高级指令和低级动作之间的差距。通过将动作预测建立在这些子目标之上，智能体可以实现更有结构和更具可解释性的行为。然而，现有方法通常存在一些局限性，例如依赖于模块化架构将高层次规划和低级控制分开，导致协调不佳和泛化能力有限。我们提出的 LoHoVLA 模型在单一统一框架中整合了高层次任务规划和低级运动控制，利用共同的视觉语言骨干来提高长时间任务中的推理、规划和泛化能力。

3 LoHoVLA

本节详细介绍了 LoHoVLA，从各种建模配置开始，然后描述了用于训练 LoHoVLA 的 LoHoSet 数据集。接着我们展示模型架构并概述训练策略。




Figure 1: 左上：Vanilla VLA 直接将高层目标和观察映射到行动。左下：分层架构将计划和执行分开——规划器推断子任务，控制器执行它们。右：LoHoVLA 将高层任务规划和低层运动控制整合到统一模型中。它使用自回归（AR）Transformer 作为其主干，并采用分层闭环控制机制。

3.1 建模配置

我们解决了学习策略 π_θ 的问题，该策略基于视觉观察 $\mathbf{o}_t$ 和高层语言目标 g 生成机器人动作 $\mathbf{a}_t$ 。视觉观察 $\mathbf{o}_t$ 包括由机器人摄像头捕捉到的场景图像。目标 g 定义了一个长时间任务的高级指令（例如，“清理桌面”），这隐含地导致多个子任务 $[\hat{g}_1, \hat{g}_2, \dots, \hat{g}_N]$ 的顺序执行（例如，“将笔放入笔筒” → “关闭笔记本电脑” → “把书放在书架上” → 等）。为简化问题，我们假设每个子任务可以在一个时间步内完成。动作 $\mathbf{a}_t$ 代表低级机器人动作，例如指定机器人的末端执行器的笛卡尔位置。这些命令由机器人执行以与环境进行互动。然后捕捉新观察 $\mathbf{o}_{t+1}$ 来确定后续动作 $\mathbf{a}_{t+1}$ 。

这个任务的一个典型轨迹可以表示为 $\{g, \gamma_1, \gamma_2, \dots, \gamma_N\}$ ，其中 g 表示整体目标， $\gamma_t = (\mathbf{o}_t, \hat{g}_t, \mathbf{a}_t)$ 表示在时间步 t 的观察、子任务和机器人动作的三元组。在推理过程中，策略仅提供整体目标，而无法访问子任务。因此，它必须依赖于隐式或显式的规划来推断子任务。

基础 VLA 基础 VLA 模型（图 1，左上方）仅限于动作生成，无法生成语言输出。因此，实际上它隐式地执行子任务规划，仅根据高层目标 g 和当前观察 $\mathbf{o}_t$ 生成一个结果动作 $\mathbf{a}_t$ ：

$$\pi_\theta(\mathbf{o}_t, g) \rightarrow \mathbf{a}_t. \quad (1)$$

层次结构架构 VLA 的隐式子任务缺乏解释性和可靠性。为了解决这一问题，层次结构架构（图 1，左下）提出使用一个外部高层规划器来根据当前观察和高层目标明确推断下一个原子子任务。然后底层控制器生成动作以执行此子任务：

$$\pi_\theta^{\text{planner}}(\mathbf{o}_t, g) \rightarrow \hat{g}_t, \pi_\theta^{\text{controller}}(\mathbf{o}_t, \hat{g}_t) \rightarrow \mathbf{a}_t. \quad (2)$$

LoHoVLA 我们提倡一种统一的范式，将高层任务规划和低层运动控制集成到一个模型中，而不是采用可能在协调不佳和建模冗余方面存在问题的独立模块（图 1 右）。形式上，有：

$$\pi_\theta(\mathbf{a}_t, \hat{g}_t | \mathbf{o}_t, g) = \pi_\theta(\mathbf{a}_t | \mathbf{o}_t, g, \hat{g}_t) \cdot \pi_\theta(\hat{g}_t | \mathbf{o}_t, g). \quad (3)$$

正如方程所暗示的，LoHoVLA 首先推断下一个原子子任务，然后将其作为上下文指导来预测机器人的动作。高层任务规划对应于建模 $\pi_\theta(\hat{g}_t | \mathbf{o}_t, g)$ ，而低层运动控制对应于建模 $\pi_\theta(\mathbf{a}_t | \mathbf{o}_t, g, \hat{g}_t)$ ，这两个分布都在统一的统一模型中表示。

3.2 用于长时间范围具体任务的合成数据集：LoHoSet

LoHoVLA 的训练依赖于一个示例集合 (g, γ_t) ，其具有 $\gamma_t = (\mathbf{o}_t, \hat{g}_t, \mathbf{a}_t)$ 。主要挑战是对于现实世界中的长时间跨度任务的子任务标注几乎不能在没有人干预的情况下以可扩展的方式获取。为了解决这个问题，我们选择基于模拟器的方法，遵循之前的工作 [38, 50, 32]。具体而言，我们基于 Ravens 机器人模拟器 [49] 构建了 LoHoSet 数据集。模拟环境包括一个带有吸盘夹具的 UR5e 机械臂和放置在桌面上的几个物体。环境仅在预测的动作在语义上正确




Figure 2: 长时间跨度集合 (LoHoSet) 的一个例子。物体属性如大小、颜色、数量和位置在不同情况下有所变化。

并成功执行时提供奖励信号。为了模拟现实世界的不确定性，模拟器增加了观察噪声并引入了一个丢弃概率 p ，使末端执行器每秒有可能将选中的块掉落。视觉观测 $\mathbf{o} = (\mathcal{I}_{\text{color}}, \mathcal{I}_{\text{depth}})$ 包括场景的 RGB 和深度自上而下的正交重建。目标指令 g 主要关注将物体重新排列到所需的配置中（例如，“在绿色区域交替堆叠积木”）。

我们根据手动设计的规则收集分解的子任务，得益于模拟器中关于场景的完整信息的可用性。具体而言，我们随机初始化场景，并直接根据目标对象的位置估计动作 $\mathbf{a} = (\mathcal{T}_{\text{pick}}, \mathcal{T}_{\text{place}})$ 。对于没有依赖约束的子任务，其执行顺序是随机的；否则，我们使用预定义的逻辑生成这些子任务。每个对象都被分配一个文本标签，该标签被插入到子任务模板中以生成子任务描述（例如，“拿起绿色方块并将其放置在绿色区域” → “拿起蓝色方块并将其放置在绿色方块上” → 等）。此过程使得可以生成大量多样化的示例。

最终的 LoHoSet 包括三种类型的物体：方块、碗和区域，总共有 11 种不同的颜色。方块有两种尺寸，大和小。遵循 LoHoRavens [50]，我们采用了 10 个长远视任务（在表格 1 中详细介绍）和 3 个抓取放置的基础任务，以便与基线进行比较。我们在 LoHoSet 中增加了 10 个额外的长远视任务，以提高训练模型的泛化能力（见图 3 左侧）。这些任务的一个例子在图 2 中展示了。有关 LoHoSet 的更多详细信息，请参见附录 A。

3.3 模型结构

LoHoVLA 采用一个大型预训练视觉语言模型 (VLM) 作为其主干来生成下一个标记，利用专门的去标记化器分别将其翻译为语言子任务和动作。为解决高级规划和低级控制中的错误，它结合了一种分层闭环控制机制。LoHoVLA 的概述如图 1 所示。

基础视觉语言模型。我们选择 PaliGemma [5] 作为我们模型的主干，因为它在之前的研究中已被证明有效 [6, 20]。PaliGemma 是一个多模态基础模型，处理图像和文本提示以生成文本。它集成了一个基于 SigLIP 的图像编码器，一个仅解码的 Gemma-2B 语言模型，以及一个线性投影层，该层将视觉特征映射到语言模型的标记空间中。

动作去标记器。根据之前的工作 [1, 7, 24]，我们将机器人动作表示为离散的标记，以便与视觉-语言数据集进行联合训练。具体来说，我们将归一化的动作值离散化为 1,024 个均匀的区间。在推理过程中，机器人动作通过去标记和去归一化来恢复。

分层闭环控制机制。与原子任务的闭环控制相比，管理长远任务更加复杂。执行失败可能源于子任务规划错误、不准确的动作预测或外部干扰。更正式地说，这三种错误类型是：(1) 子任务规划错误，(2) 子任务规划正确但动作预测错误，以及 (3) 规划和预测都正确，但由于外部干扰导致失败。LoHoVLA 采用一种分层闭环控制策略，其动作预测的频率高于子任务重规划的频率。具体来说，如果在当前子任务期间的失败次数超过预定义的阈值 K ，系统将触发子任务重规划；否则，它只重新预测动作。评估期间使用的控制程序在算法 1 中列出。我们假设机器人在完成子任务后会获得一个正奖励 r 。done 标志用于确定总体目标是否已经实现。

这种设计避免了在情况 (2) 和 (3) 中的不必要的子任务重新规划。我们的实验表明，分层闭环控制方案有效地减轻了长时间任务中的错误，同时避免了冗余的推理步骤。

在训练 LoHoVLA 时，我们优化语言模型的主干网络，而保持图像编码器和线性映射层不变。训练目标由两个组成部分构成：子任务生成和动作预测。两个输出都由语言模型头部产生，并使用交叉熵损失进行优化。总损失定义为：

$$\mathcal{L} = \mathcal{L}_{\text{text}} + \mathcal{L}_{\text{action}}. \quad (4)$$

Algorithm 1: LoHoVLA 测试时闭环控制

Data: LoHoVLA policy π_θ , initial observation $\mathbf{o}_0$, high-level goal g , reward r , failure count k , failure threshold K , done flag $done$

$t \leftarrow 0, k \leftarrow 0, r \leftarrow 0, done \leftarrow false$

while not $done$ **do**

if $t = 0$ or $r > 0$ or $k > K$ **then**

$\hat{g}_t \sim \pi_\theta(\hat{g}_t \mid \mathbf{o}_t, g)$;

$k \leftarrow 0$;

end

$\mathbf{a}_t \sim \pi_\theta(\mathbf{a}_t \mid \mathbf{o}_t, g, \hat{g}_t)$;

 execute $\mathbf{a}_t$;

 get $\mathbf{o}_{t+1}, r, done$ from environment;

if $r = 0$ **then**

$k \leftarrow k + 1$;

end

$t \leftarrow t + 1$;

end

Table 1: LoHoRavens 基准测试中的已见任务和未见任务。请注意，我们还将拾取和放置原始任务添加到已见任务中。

Tasks		Instruction
Seen Tasks	A. pick-and-place-primitive	"Put the [OBJ] on the [OBJ / POS]."
	B. put-block-into-matching-bowl	"Put the blocks in the bowls with matching colors."
	C. stack-smaller-over-bigger-with-same-color	"Stack smaller blocks over bigger blocks of the same color."
	D. stack-block-in-absolute-area	"Stack all the blocks in the [ABS POS] area."
	E. put-even-blocks-in-same-color-zone	"Move all blocks of a color that occur in even numbers."
Unseen Tasks	F. put-block-into-mismatching-bowl	"Put the blocks in the bowls with mismatching colors."
	G. stack-blocks-of-same-size	"Stack blocks of the same size."
	H. stack-blocks-with-alternate-color	"Stack blocks in alternate colors."
	I. stack-smaller-over-bigger-with-same-color-in-same-color-zone	"Stack blocks of the same color in the zone with same color, with the bigger blocks underneath."
	J. move-blocks-between-absolute-positions	"Move all the blocks in the [ABS POS] area to the [ABS POS] area."
	K. stack-blocks-of-same-size	"Stack blocks of the same color."

我们采用两阶段的训练策略。在第一阶段，我们在长视野任务上微调 PaliGemma，仅优化文本损失，以改善高层次任务规划。在第二阶段，我们通过挑选和放置基本任务来扩展数据集，并优化文本和动作损失，以增强动作预测。

4 实验

我们的实验评估旨在评估 LoHoVLA 在高层次任务规划、低层次运动控制以及对训练中未见的新任务的泛化能力。具体而言，我们关注以下问题：

- How does LoHoVLA perform compared to hierarchical architecture baselines and standard VLA models in terms of performance and generalization on long-horizon tasks?
- How effective are hierarchical closed-loop control schemes at mitigating errors in long-horizon tasks, where failures can arise from both high-level task planning and low-level motion control?
- Can dataset expansion and a two-stage training strategy improve overall model performance?

4.1 实验设置

基准。我们使用层次结构的 LoHoRavens [50] 作为基准。它由高层次子任务规划的规划器、低层次运动控制的执行器和反馈驱动闭环控制的报告器组成。它支持两种基于报告器的反馈类型：(1) 显式反馈，其中由规划器 (LLaMA 2 13B [40]) 生成子任务，执行器 (CLIPort [38]) 执行这些任务，报告器 (OpenFlamingo [3]) 提供结果说明以改善未来的计划；(2) 隐式反

Table 2: 在 LoHoRavens 基准上的平均奖励 (%) 和成功率 (%) 比较。加粗条目表示最高成功率, 下划线条目表示第二高成功率。

Tasks		Vanilla VLA	LoHoRavens		LoHoVLA
			Explicit feedback	Implicit feedback	
Seen Tasks	A	79.0 / 79.0	67.3 / -	67.3 / -	<u>77.5</u> / 77.5
	B	14.9 / 0.0	31.4 / -	<u>37.0</u> / -	97.8 / 91.5
	C	<u>26.8</u> / 0.5	18.0 / -	22.1 / -	34.9 / 22.5
	D	32.3 / 3.0	30.4 / -	<u>33.2</u> / -	35.8 / 11.5
	E	<u>22.1</u> / 3.5	9.6 / -	8.2 / -	85.1 / 81.0
Unseen Tasks	F	<u>52.1</u> / 9.0	28.5 / -	21.1 / -	86.1 / 41.0
	G	6.8 / 0.0	<u>21.9</u> / -	14.7 / -	40.1 / 25.0
	H	7.3 / 0.0	<u>13.2</u> / -	5.2 / -	16.7 / 7.5
	I	<u>43.1</u> / 1.5	12.8 / -	11.7 / -	77.2 / 52.0
	J	<u>38.6</u> / 10.5	27.4 / -	27.2 / -	43.6 / 22.0
	K	<u>58.2</u> / 33.0	4.0 / -	6.8 / -	73.8 / 54.5

馈, 其中报告器使用冻结的 CLIP 模型 [35] 对视觉观察进行编码, 通过 MLP 投射, 并通过 LLaVA [29] 将嵌入发送给规划器以进行连续计划调整。

作为次要基线, 我们训练了一个普通的 VLA 模型, 以隔离显式子任务预测的影响。该模型直接预测低层次的机器人动作, 而不产生中间语言输出, 仅依赖于隐式子任务推理。我们的目标是测试该模型是否能够在没有显式规划的情况下学习子任务推理。

训练细节。LoHoVLA 使用 PaliGemma-3b-mix-224 模型作为骨干, 并分两个阶段进行训练。在第一阶段, 我们对 PaliGemma 进行微调, 涉及 14 个长时间跨度的任务——包括 4 个来自 LoHoRavens 的已知任务和 10 个我们设计的额外任务——每个任务有 1,000 个示例。我们仅优化文本损失以改进高层次的任务规划。不像 LoHoRavens 使用提示工程来保持泛化能力, 我们的模型需要微调, 这导致在仅有的 4 个任务上出现过拟合。为了解决这一问题, 我们加入了 10 个额外的任务以增强泛化能力。在第二阶段, 我们对数据集进行扩充, 为每个抓取和放置的基本动作增加 10,000 个示例, 并同时优化文本和动作损失以提高低层次的运动控制能力。

训练采用带有权重衰减和梯度裁剪的 AdamW 优化器 [31]。我们使用 DeepSpeed [36] 进行高效的分布式训练。在训练阶段一, 我们使用 8 个 NVIDIA 4090 GPU (24GB VRAM), 每个设备的批大小为 2, 学习率为 $5e-5$, 训练 3 个周期。我们对所有线性层应用 LoRA [17], 秩为 16。在训练阶段二, 我们使用学习率 $1e-5$ 进行 1 个周期, 其他设置保持不变。为了对比, 我们在相同的数据集上使用学习率 $1e-5$ 训练标准的 VLA 模型, 不使用子任务标签, 训练 5 个周期, 硬件和 LoRA 配置相同。

评估指标。根据任务类别, 判断对象状态是否符合真实情况的方法有两种。第一种是姿态匹配, 要求对象的位置和方向与真实情况完全对齐。第二种是区域匹配, 要求预测对象与真实对象的重叠面积超过预定的阈值。我们根据完成挑选和放置步骤的正确比例, 对每个任务实例进行从 0 (失败) 到 100 (成功) 的评分。例如, 如果一个任务需要十个步骤而模型完成了八个步骤, 则得分为 80 %。在我们的评估中, 我们报告测试集上的平均得分和成功率。

4.2 主要结果

我们在来自 LoHoRavens 的已见和未见任务中, 对 LoHoVLA 与基础 VLA 以及 LoHoRavens 进行了评估 (表格 1)。LoHoVLA 和基础 VLA 是在五个已见任务和本文中介绍的十个额外任务上进行训练的。评估结果, 包括对具有显式和隐式反馈机制的 LoHoRavens 的评估结果, 显示在表格 2。

LoHoVLA 在几乎所有任务中都获得了最高的平均得分和成功率。在把方块放进匹配碗的任务中, 它达到了接近完美的准确率。在最具挑战性的推理任务——将偶数方块放入同色区域中, 它需要整合颜色识别、计数、空间推理和逻辑, LoHoVLA 取得了 85.1 分和 81.0 的成

功率，而所有基准模型的表现都很差。值得注意的是，LoHoVLA 展现了对新任务的强大泛化能力，尽管没有先前的经验，但其表现始终优于所有基准模型。

有趣的是，LoHoVLA 在长视距任务中偶尔比选择并放置原始任务表现更好。这主要归因于评估标准的差异：区域匹配任务（例如，涉及碗或颜色区域）允许轻微的空间误差，这正是 LoHoVLA 能够有效处理的。相比之下，姿势匹配任务（例如，积木堆叠）要求精确对齐，偶尔出现的次优运动轨迹可能会略微降低性能。尽管如此，LoHoVLA 在这两种任务类型中都表现出了强大的适应能力。

Vanilla VLA 在所有模型中表现最差，在多个任务上成功率为零。我们的定性分析显示，这主要是由于缺乏子任务监督，导致模型过度拟合训练数据中的常见模式。例如，在将积木放入匹配碗的任务中，它经常把积木放入错误的碗中，不考虑目标条件。

4.3 闭环策略比较

为评估我们专门设计的闭环控制机制在解决任务执行失败方面的有效性，我们比较以下三种控制策略。

- Strategy (a). On failure, the system re-predicts the action only without re-planning the sub-task.
- Strategy (b). The system re-plans the sub-task and then re-predicts the action after every failure.
- Strategy (c). The hierarchical closed-loop control strategy: if the number of failures within the current sub-task exceeds a predefined threshold K , the system initiates sub-task re-planning; otherwise, it only re-predicts the action. In our experiments, we set $K = 2$.

除了测量平均奖励和成功率之外，我们还追踪高级子任务规划的次数。所有三种策略都使用微调后的 LoHoVLA 模型进行评估。结果在表 ?? 中报告。

如预期的那样，策略 (a) 导致了最差的性能。当失败源于错误的子任务规划时，这种方法继续执行有缺陷的计划，可能导致死锁。策略 (b) 和 (c) 在总体指标上表现相当；然而，策略 (c) 需要较少的高层次子任务规划步骤。这是因为许多失败是由低层次预测错误或外部干扰引起的，这种情况下重新规划子任务是没有必要的。

此外，任务特性会影响策略表现。在需要大量推理的任务（例如，在同色区域内放置偶数块），策略 (b) 通过及时纠正子任务分配表现突出。相比之下，对于需要精确运动控制的任务（例如，将块堆放在绝对区域内），策略 (c) 表现更好，因为重复的低层次尝试提高了成功的可能性。




Figure 3: (a) 比较在有和没有数据集扩展的情况下，模型在未见任务上的表现，使用子任务规划成功率 (%) 进行评估。(b) 比较单阶段和两阶段训练策略之间的性能，使用子任务规划成功率 (%) 和任务完成成功率 (%) 进行评估。

4.4 消融研究

我们研究了训练集扩展和两阶段训练方法对模型性能的影响。为了更好地评估规划能力，我们引入了一项新的指标：子任务规划成功率。与子任务执行成功不同，这项指标通过去掉低层次动作预测和外部干扰的影响来单独评估规划性能。具体来说，对于每个任务，我们从所有片段中随机抽取 10 个时间步长，并手动枚举所有有效的后续子任务。然后使用 LLM 评估模型在每个时间步长上预测的子任务是否在语义上等同于任何枚举的真实选项。更多细节在附录 B 中提供。

评估训练集扩展。我们在有和没有训练集扩展的情况下训练了 LoHoVLA（即，使用了第 3.2 节中提到的额外 10 个任务进行训练），并在 LoHoRavens 基准测试的未见任务上评估了泛化能力。结果如图 3 左所示。可以观察到，没有使用额外数据训练的模型泛化能力较差。这是由于对已见任务的严重过拟合所致。例如，任务 `put-block-into-mismatching-bowl` 的成功率为 0，因为该场景与 `put-block-into-matching-bowl` 场景相似，导致模型过拟合于后者，忽略了语言目标，而是将块放入了颜色匹配的碗中。扩展的数据集缓解了这种过拟合问题。

评估两阶段训练。我们在使用相同配置的 LoHoVLA 上进行单阶段和两阶段训练实验。在这两种设置下，模型都训练 5 个周期。关键的区别在于，两阶段方法中，原始任务和动作标签是在前三个周期后才引入的。结果——平均子任务计划成功率（%）和平均任务成功率（%）——如图 3 右所示。单阶段训练设置产生了较低子任务计划成功率，从而导致任务成功率降低。这表明过早引入动作标签和原始任务会阻碍高层次任务规划的有效优化。

对于需要高层规划和低层控制的长时间范围具体化任务，现有的 VLA 模型和分层方法在规划和协调上表现不佳。为了解决这个问题，我们提出了 LoHoVLA，这是一种统一的 VLA 框架，利用一个大型预训练的视觉-语言模型共同生成子任务和机器人动作。它结合了分层闭环控制机制，以纠正两个层次上的错误。实验证明，LoHoVLA 在性能上优于之前的 VLA 和分层方法，并表现出很强的泛化能力。

局限性。局限性主要源于机器人动作的离散结构导致的有限精度。此外，我们假设一个子任务可以在一个时间步内完成，这在实时应用中可能不切实际。

References

- [1] Michael Ahn, Anthony Brohan, Noah Brown, Yevgen Chebotar, Omar Cortes, Byron David, Chelsea Finn, Chuyuan Fu, Keerthana Gopalakrishnan, Karol Hausman, et al. Do as i can, not as i say: Grounding language in robotic affordances. *arXiv preprint arXiv:2204.01691*, 2022.
- [2] Jean-Baptiste Alayrac, Jeff Donahue, Pauline Luc, Antoine Miech, Iain Barr, Yana Hasson, Karel Lenc, Arthur Mensch, Katherine Millican, Malcolm Reynolds, et al. Flamingo: a visual language model for few-shot learning. *Advances in neural information processing systems*, 35: 23716–23736, 2022.
- [3] Anas Awadalla, Irena Gao, Josh Gardner, Jack Hessel, Yusuf Hanafy, Wanrong Zhu, Kalyani Marathe, Yonatan Bitton, Samir Gadre, Shiori Sagawa, et al. Openflamingo: An open-source framework for training large autoregressive vision-language models. *arXiv preprint arXiv:2308.01390*, 2023.
- [4] Suneel Belkhale, Tianli Ding, Ted Xiao, Pierre Sermanet, Quon Vuong, Jonathan Tompson, Yevgen Chebotar, Debidatta Dwibedi, and Dorsa Sadigh. Rt-h: Action hierarchies using language. *arXiv preprint arXiv:2403.01823*, 2024.
- [5] Lucas Beyer, Andreas Steiner, André Susano Pinto, Alexander Kolesnikov, Xiao Wang, Daniel Salz, Maxim Neumann, Ibrahim Alabdulmohsin, Michael Tschannen, Emanuele Bugliarello, et al. Paligemma: A versatile 3b vlm for transfer. *arXiv preprint arXiv:2407.07726*, 2024.
- [6] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. π_0 : A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.
- [7] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. *arXiv preprint arXiv:2307.15818*, 2023.
- [8] Chi-Lam Cheang, Guangzeng Chen, Ya Jing, Tao Kong, Hang Li, Yifeng Li, Yuxiao Liu, Hongtao Wu, Jiafeng Xu, Yichu Yang, et al. Gr-2: A generative video-language-action model with web-scale knowledge for robot manipulation. *arXiv preprint arXiv:2410.06158*, 2024.
- [9] Hongyi Chen, Yunchao Yao, Ruixuan Liu, Changliu Liu, and Jeffrey Ichnowski. Automating robot failure recovery using vision-language models with optimized prompts. *arXiv preprint arXiv:2409.03966*, 2024.
- [10] Xi Chen, Xiao Wang, Lucas Beyer, Alexander Kolesnikov, Jialin Wu, Paul Voigtlaender, Basil Mustafa, Sebastian Goodman, Ibrahim Alabdulmohsin, Piotr Padlewski, et al. Pali-3 vision language models: Smaller, faster, stronger. *arXiv preprint arXiv:2310.09199*, 2023.
- [11] An-Chieh Cheng, Yandong Ji, Zhaojing Yang, Zaitian Gongye, Xueyan Zou, Jan Kautz, Erdem Biyik, Hongxu Yin, Sifei Liu, and Xiaolong Wang. Navila: Legged robot vision-language-action model for navigation. *arXiv preprint arXiv:2412.04453*, 2024.
- [12] Yinpei Dai, Jayjun Lee, Nima Fazeli, and Joyce Chai. Racer: Rich language-guided failure recovery policies for imitation learning. *arXiv preprint arXiv:2409.14674*, 2024.
- [13] Danny Driess, Fei Xia, Mehdi SM Sajjadi, Corey Lynch, Aakanksha Chowdhery, Ayzaan Wahid, Jonathan Tompson, Quan Vuong, Tianhe Yu, Wenlong Huang, et al. Palm-e: An embodied multimodal language model. 2023.
- [14] Jiafei Duan, Samson Yu, Hui Li Tan, Hongyuan Zhu, and Cheston Tan. A survey of embodied ai: From simulators to research tasks. *IEEE Transactions on Emerging Topics in Computational Intelligence*, 6(2):230–244, 2022.
- [15] Lutfi Eren Erdogan, Nicholas Lee, Sehoon Kim, Suhong Moon, Hiroki Furuta, Gopala Anumanchipalli, Kurt Keutzer, and Amir Gholami. Plan-and-act: Improving planning of agents for long-horizon tasks. *arXiv preprint arXiv:2503.09572*, 2025.

- [16] Ziyu Guo, Renrui Zhang, Xiangyang Zhu, Chengzhuo Tong, Peng Gao, Chunyuan Li, and Pheng-Ann Heng. Sam2point: Segment any 3d as videos in zero-shot and promptable manners. *arXiv preprint arXiv:2408.16768*, 2024.
- [17] Edward J Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang, Weizhu Chen, et al. Lora: Low-rank adaptation of large language models. *ICLR*, 1(2):3, 2022.
- [18] Yingdong Hu, Fanqi Lin, Tong Zhang, Li Yi, and Yang Gao. Look before you leap: Unveiling the power of gpt-4v in robotic vision-language planning. *arXiv preprint arXiv:2311.17842*, 2023.
- [19] Wenlong Huang, Fei Xia, Ted Xiao, Harris Chan, Jacky Liang, Pete Florence, Andy Zeng, Jonathan Tompson, Igor Mordatch, Yevgen Chebotar, et al. Inner monologue: Embodied reasoning through planning with language models. *arXiv preprint arXiv:2207.05608*, 2022.
- [20] Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025.
- [21] Stephen James, Zicong Ma, David Rovick Arrojo, and Andrew J Davison. Rlbench: The robot learning benchmark & learning environment. *IEEE Robotics and Automation Letters*, 5(2): 3019–3026, 2020.
- [22] Yunfan Jiang, Agrim Gupta, Zichen Zhang, Guanzhi Wang, Yongqiang Dou, Yanjun Chen, Li Fei-Fei, Anima Anandkumar, Yuke Zhu, and Linxi Fan. Vima: General robot manipulation with multimodal prompts. *arXiv preprint arXiv:2210.03094*, 2(3):6, 2022.
- [23] Siddharth Karamcheti, Suraj Nair, Ashwin Balakrishna, Percy Liang, Thomas Kollar, and Dorsa Sadigh. Prismatic vlms: Investigating the design space of visually-conditioned language models. In *Forty-first International Conference on Machine Learning*, 2024.
- [24] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, et al. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024.
- [25] Boyi Li, Philipp Wu, Pieter Abbeel, and Jitendra Malik. Interactive task planning with language models. *arXiv preprint arXiv:2310.10645*, 2023.
- [26] Xinghang Li, Peiyan Li, Minghuan Liu, Dong Wang, Jirong Liu, Bingyi Kang, Xiao Ma, Tao Kong, Hanbo Zhang, and Huaping Liu. Towards generalist robot policies: What matters in building vision-language-action models. *arXiv preprint arXiv:2412.14058*, 2024.
- [27] Yi Li, Yuquan Deng, Jesse Zhang, Joel Jang, Marius Memmel, Raymond Yu, Caelan Reed Garrett, Fabio Ramos, Dieter Fox, Anqi Li, et al. Hamster: Hierarchical action models for open-world robot manipulation. *arXiv preprint arXiv:2502.05485*, 2025.
- [28] Jacky Liang, Wenlong Huang, Fei Xia, Peng Xu, Karol Hausman, Brian Ichter, Pete Florence, and Andy Zeng. Code as policies: Language model programs for embodied control. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 9493–9500. IEEE, 2023.
- [29] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. *Advances in neural information processing systems*, 36:34892–34916, 2023.
- [30] Yang Liu, Weixing Chen, Yongjie Bai, Xiaodan Liang, Guanbin Li, Wen Gao, and Liang Lin. Aligning cyber space with physical world: A comprehensive survey on embodied ai. *arXiv preprint arXiv:2407.06886*, 2024.
- [31] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. *arXiv preprint arXiv:1711.05101*, 2017.

- [32] Yuan Meng, Xiangtong Yao, Haihui Ye, Yirui Zhou, Shengqiang Zhang, Zhenshan Bing, and Alois Knoll. Data-agnostic robotic long-horizon manipulation with vision-language-guided closed-loop feedback. *arXiv preprint arXiv:2503.21969*, 2025.
- [33] Soroush Nasiriany, Fei Xia, Wenhao Yu, Ted Xiao, Jacky Liang, Ishita Dasgupta, Annie Xie, Danny Driess, Ayzaan Wahid, Zhuo Xu, et al. Pivot: Iterative visual prompting elicits actionable knowledge for vlms. *arXiv preprint arXiv:2402.07872*, 2024.
- [34] Abby O’Neill, Abdul Rehman, Abhiram Maddukuri, Abhishek Gupta, Abhishek Padalkar, Abraham Lee, Acorn Pooley, Agrim Gupta, Ajay Mandlekar, Ajinkya Jain, et al. Open x-embodiment: Robotic learning datasets and rt-x models: Open x-embodiment collaboration 0. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 6892–6903. IEEE, 2024.
- [35] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In *International conference on machine learning*, pages 8748–8763. PmlR, 2021.
- [36] Jeff Rasley, Samyam Rajbhandari, Olatunji Ruwase, and Yuxiong He. Deepspeed: System optimizations enable training deep learning models with over 100 billion parameters. In *Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining*, pages 3505–3506, 2020.
- [37] Lucy Xiaoyang Shi, Zheyuan Hu, Tony Z Zhao, Archit Sharma, Karl Pertsch, Jianlan Luo, Sergey Levine, and Chelsea Finn. Yell at your robot: Improving on-the-fly from language corrections. *arXiv preprint arXiv:2403.12910*, 2024.
- [38] Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Cliport: What and where pathways for robotic manipulation. In *Conference on robot learning*, pages 894–906. PMLR, 2022.
- [39] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, et al. Octo: An open-source generalist robot policy. *arXiv preprint arXiv:2405.12213*, 2024.
- [40] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale, et al. Llama 2: Open foundation and fine-tuned chat models. *arXiv preprint arXiv:2307.09288*, 2023.
- [41] Zixuan Wang, Bo Yu, Junzhe Zhao, Wenhao Sun, Sai Hou, Shuai Liang, Xing Hu, Yinhe Han, and Yiming Gan. Karma: Augmenting embodied ai agents with long-and-short term memory systems. *arXiv preprint arXiv:2409.14908*, 2024.
- [42] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Fei Xia, Ed Chi, Quoc V Le, Denny Zhou, et al. Chain-of-thought prompting elicits reasoning in large language models. *Advances in neural information processing systems*, 35:24824–24837, 2022.
- [43] Junjie Wen, Minjie Zhu, Yichen Zhu, Zhibin Tang, Jinming Li, Zhongyi Zhou, Chengmeng Li, Xiaoyu Liu, Yaxin Peng, Chaomin Shen, et al. Diffusion-vla: Scaling robot foundation models via unified diffusion and autoregression. *arXiv preprint arXiv:2412.03293*, 2024.
- [44] Junjie Wen, Yichen Zhu, Jinming Li, Zhibin Tang, Chaomin Shen, and Feifei Feng. Dexvla: Vision-language model with plug-in diffusion expert for general robot control. *arXiv preprint arXiv:2502.05855*, 2025.
- [45] Zhenyu Wu, Ziwei Wang, Xiuwei Xu, Jiwen Lu, and Haibin Yan. Embodied task planning with large language models. *arXiv preprint arXiv:2307.01848*, 2023.
- [46] Zhutian Yang, Caelan Garrett, Dieter Fox, Tomás Lozano-Pérez, and Leslie Pack Kaelbling. Guiding long-horizon task and motion planning with vision language models. *arXiv preprint arXiv:2410.02193*, 2024.

- [47] Tianhe Yu, Deirdre Quillen, Zhanpeng He, Ryan Julian, Karol Hausman, Chelsea Finn, and Sergey Levine. Meta-world: A benchmark and evaluation for multi-task and meta reinforcement learning. In *Conference on robot learning*, pages 1094–1100. PMLR, 2020.
- [48] Michał Zawalski, William Chen, Karl Pertsch, Oier Mees, Chelsea Finn, and Sergey Levine. Robotic control via embodied chain-of-thought reasoning. *arXiv preprint arXiv:2407.08693*, 2024.
- [49] Andy Zeng, Pete Florence, Jonathan Tompson, Stefan Welker, Jonathan Chien, Maria Attarian, Travis Armstrong, Ivan Krasin, Dan Duong, Vikas Sindhwani, et al. Transporter networks: Rearranging the visual world for robotic manipulation. In *Conference on Robot Learning*, pages 726–747. PMLR, 2021.
- [50] Shengqiang Zhang, Philipp Wicke, Lütfi Kerem Şenel, Luis Figueredo, Abdeldjallil Naceri, Sami Haddadin, Barbara Plank, and Hinrich Schütze. Lohoravens: A long-horizon language-conditioned benchmark for robotic tabletop manipulation. *arXiv preprint arXiv:2310.12020*, 2023.
- [51] Shiduo Zhang, Zhe Xu, Peiju Liu, Xiaopeng Yu, Yuan Li, Qinghui Gao, Zhaoye Fei, Zhangyue Yin, Zuxuan Wu, Yu-Gang Jiang, et al. Vlabench: A large-scale benchmark for language-conditioned robotics manipulation with long-horizon reasoning tasks. *arXiv preprint arXiv:2412.18194*, 2024.
- [52] Chao Zhao, Shuai Yuan, Chunli Jiang, Junhao Cai, Hongyu Yu, Michael Yu Wang, and Qifeng Chen. Erra: An embodied representation and reasoning architecture for long-horizon language-conditioned manipulation tasks. *IEEE Robotics and Automation Letters*, 8(6):3230–3237, 2023.
- [53] Qingqing Zhao, Yao Lu, Moo Jin Kim, Zipeng Fu, Zhuoyang Zhang, Yecheng Wu, Zhaoshuo Li, Qianli Ma, Song Han, Chelsea Finn, et al. Cot-vla: Visual chain-of-thought reasoning for vision-language-action models. *arXiv preprint arXiv:2503.22020*, 2025.
- [54] Zhehua Zhou, Jiayang Song, Kunpeng Yao, Zhan Shu, and Lei Ma. Isr-llm: Iterative self-refined large language model for long-horizon sequential task planning. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 2081–2088. IEEE, 2024.
- [55] Yuke Zhu, Josiah Wong, Ajay Mandlekar, Roberto Martín-Martín, Abhishek Joshi, Soroush Nasiriany, and Yifeng Zhu. robosuite: A modular simulation framework and benchmark for robot learning. *arXiv preprint arXiv:2009.12293*, 2020.

A LoHoSet




Figure 4: LoHoSet 数据集中所有任务的视觉示例，包括 3 个拾取与放置基本操作和 20 个长时间跨度任务，展示任务场景的多样性和复杂性。

LoHoSet 包括 3 个挑选和放置的基本任务和 20 个长视距任务。其中，10 个长视距任务和所有 3 个基本任务都从 LoHoRavens 基准中改编，以便于与现有基线进行比较。引入另外 10 个长视距任务是为了提高训练模型的泛化能力。任务的完整列表见表格 3，所有任务的示例在图 4 中展示。

Table 3: LoHoSet 中所有任务的总结，包括 3 项基本的拾取和放置任务及 20 项长时间任务，区分了那些从 LoHoRavens 中采用的任务和那些为改进泛化而引入的任务。

Tasks		Instruction
LoHoRavens Seen Tasks	pick-and-place-primitive	“Put the [OBJ] on the [OBJ].”
	pick-and-place-primitive-with-size	“Put the [SIZE] [OBJ] on the [SIZE] [OBJ].”
	pick-and-place-primitive-with-absolute-position	“Put the [OBJ] on the [ABS_POS].”
	put-block-into-matching-bowl	“Put the blocks in the bowls with matching colors.”
	stack-smaller-over-bigger-with-same-color	“Stack smaller blocks over bigger blocks of the same color.”
	stack-block-in-absolute-area	“Stack all the blocks in the [ABS_POS] area.”
	put-even-blocks-in-same-color-zone	“Move all blocks of a color that occur in even numbers.”
LoHoRavens Unseen Tasks	put-block-into-mismatching-bowl	“Put the blocks in the bowls with mismatching colors.”
	stack-blocks-of-same-size	“Stack blocks of the same size.”
	stack-blocks-with-alternate-color	“Stack blocks in alternate colors.”
	stack-smaller-over-bigger-with-same-color-in-same-color-zone	“Stack blocks of the same color in the zone with same color, with the bigger blocks underneath.”
	move-blocks-between-absolute-positions	“Move all the blocks in [ABS_POS] area to [ABS_POS] area.”
	stack-blocks-of-same-color	“Stack blocks of the same color.”
Additional Tasks	put-block-into-mismatching-zone	“Put the blocks in the zones with mismatching colors.”
	put-hidden-blocks-in-two-layer-towers-into-matching-bowls	“Put all the hidden blocks in the two-layer stacked towers into the bowls with matching colors.”
	put-hidden-blocks-in-two-layer-towers-into-mismatching-bowls	“Put all the hidden blocks in the two-layer stacked towers into the bowls with mismatching colors.”
	put-hidden-blocks-in-three-layer-towers-into-matching-bowls	“Put all the hidden blocks in the three-layer stacked towers into the bowls with matching colors.”
	put-hidden-blocks-in-pyramid-into-matching-bowls	“Put all the hidden blocks on the first layer of the pyramid into the bowls with matching colors.”
	stack-bigger-over-smaller-with-same-color-in-same-color-zone	“Stack blocks of the same color in the zone with same color, with the smaller blocks underneath.”
	stack-all-blocks-on-a-zone	“Stack all the blocks on the [COLOR] zone.”
	stack-blocks-by-relative-position	“Stack all the blocks on the [REL_POS] of the [COLOR] block on the [COLOR] zone.”
	move-blocks-between-absolute-positions-by-size	“Move all the [SIZE] blocks in the [ABS_POS] area to the [ABS_POS] area.”
	move-blocks-between-absolute-positions-by-color	“Move all the [COLOR] blocks in the [ABS_POS] area to the [ABS_POS] area.”

B 消融研究细节

我们研究了训练集扩展和两阶段训练策略对模型性能的影响。为了更准确地评估计划能力，我们引入了一项新指标：子任务计划成功率。与子任务执行成功不同，这一指标通过排除低级动作预测和外部噪声的影响来独立评估高级别的计划能力。对于每个任务，我们随机从所有情节中采样 10 个时间步，并手动列出有效的下一个子任务。然后，一个大型语言模型 (LLM) 评估模型在每个时间步预测的子任务是否在语义上等同于任何一个真实选项。评估提示如下：

Evaluation Prompt

You are given the current sub-task in a sequential task and a predicted next sub-task generated by a model. Additionally, you are provided with a list of valid ground-truth next sub-tasks. Determine whether the predicted sub-task is semantically equivalent to any of the ground-truth options. Focus solely on semantic similarity in intent and meaning, ignoring differences in wording or phrasing. Respond with 'Yes' if the prediction is semantically equivalent to at least one ground-truth sub-task; otherwise, respond with 'No'.