

D-LIO: 基于同时截断距离场映射的六自由度直接激光雷达惯性测程

L. Coto-Elena¹, J.E. Maese¹, L. Merino¹ and F. Caballero¹

Abstract—本文提出了一种基于在 CPU 上同时构建截断距离场的新方法，用于 6 自由度直接激光雷达惯性测程 (D-LIO)。这种连续的方式（在点的附近）可以在线处理原始 3D LiDAR 数据，避免了 LiDAR 特征选择和跟踪的需要，简化了测距管线，并易于推广到多种场景。该方法基于所提出的快速截断距离场 (Fast-TDF) 方法，作为表示环境的便捷工具。这样的表示使得 i) 可以将 LiDAR 点云配准作为一个非线性优化过程解决，而不需要在输入数据中选择/跟踪 LiDAR 特征，ii) 同时生成环境的准确截断距离场地图，以及 iii) 不论地图大小都能在恒定时间内更新该地图。该方法使用开放数据集进行了测试，包括空中和地面数据集，并与其他最先进的测距方法进行了基准测试，展示了相同或更高的精度水平，并附加了一个在线生成的环境 TDF 表示的附加值，可以用于其他机器人任务，如规划或碰撞规避。源代码在 <https://anonymous.4open.science/r/D-LIO> 公开。

I. 介绍

精准的车辆定位是机器人技术中的一个关键方面，直接影响到自主导航、远程探测和其他高级应用。为了提高定位精度，各种技术被用来结合来自不同传感器的数据，例如照相机、惯性测量单元 (IMU)、LiDAR 和雷达 [1]。基于 LiDAR 的方法 [2] 广泛使用，因为它们能够提供不受光照条件影响的高密度和精确的三维数据。这些技术已被证明能够提供准确的定位，同时也实现了环境映射 [3] [4]。然而，它们也有一定的局限性。在特征稀疏的环境中，传统的基于特征的技术 [5] [6] 可能难以提取可靠的信息，导致次优的定位。此外，在处理极其密集的点云时，计算成本显著增加，使得实时执行变得具有挑战性。

除了传感器的选择外，底层地图表示对定位系统的准确性和效率起着关键作用。大多数先进的 LiDAR SLAM 方法将地图表示为点云 (3D 点和/或特征)，并结合用于 LiDAR 配准的类似 ICP 的方法 [7] [2]。虽然有效，但这些离散表示通常在可扩展性、稀疏性和可微分性方面面临挑战 [8] [9]。为了应对这些限制，距离场，特别是符号和截断距离场 [10]，已成为一种有前景的替代方案。这些体积表示以连续的方式捕捉障碍物的接近度，对于点云配准任务尤其有利，因为它们提供平滑的梯度和隐式的表面描述。然而，对 LiDAR SLAM 的应用仍然仅限于相对较小的体积（房间、房屋楼层等）或由于大的量化误差而阻碍其在通用应用中的使用 [11] [12]。因此，大多数现有的 LiDAR 距离场方法主要专注于地图构建，假设传感器定位是完美的 [13] [8]。

据我们所知，本文首次提出了一种基于大体积内截断距离场同时建图的 6 自由度激光雷达惯性 SLAM 方法。

*This work is partially supported by the grants INSERTION (PID2021-127648OB-C31) and NORDIC (TED2021-132476B-I00), both funded by the “Agencia Estatal de Investigación – Ministerio de Ciencia, Innovación y Universidades” and the “European Union NextGenerationEU/PRTR”.

¹The authors are with the Service Robotics Laboratory, Universidad Pablo de Olavide, Seville, Spain. {lcotele,jemaecalv,lmercab,fcaballero}@upo.es

尽管该方法具有并行化的潜力，但仅使用 CPU 即可接近实时地进行环境建图和里程计估计。与基于学习的方法不同，提出的 Fast-TDF 方法能够从第一次扫描开始提供对环境的准确表示。

本文的结构如下。首先，第 II 节分析了 LiDAR 里程计和距离场计算的最新技术状态。随后，在第 ?? 节中介绍了提出的快速截断距离场方法。接下来，第 III 节详细介绍了基于同时 TDF 映射的 LiDAR-惯性里程计方法。第 IV 节使用公开数据集和开源的 LiDAR 里程计方法对所提出的方法进行测试和基准化。最后，第 V 节给出了结论和未来的工作。

II. 最新进展

A. 基于 LiDAR 的里程计

现代基于激光雷达的里程计依赖高分辨率的 3D 点云来估计运动，与相机相比，它具有在不依赖环境光照条件下操作的关键优势。传统方法如 ICP [14] 和 NDT [15] 通过最小化对齐误差来注册连续扫描。这些方法已通过 GICP [7]、CT-ICP [16] 和 KISS-ICP [2] 等方法得到了增强，从而提高了鲁棒性和计算效率。此外，诸如 IMLS-SLAM [17] 和 DLO [4] 的扫描到地图策略利用累积的地图信息来增强定位稳定性。

为了减少计算成本，基于特征的方法不是使用整个点云，而是提取几何结构。LOAM [3] 首创了这种方法，通过检测边缘和平面特征，后续的 LeGO-LOAM [5] 和 SuMa++ [18] 扩展了这一方法，结合了分割和语义约束。其他方法，如 F-LOAM [6]，进一步优化了特征的选择和表示，以实现稳健的里程计。

基于深度学习的里程计已经出现，以解决特征一致性和匹配的挑战。LO-Net [19] 通过预测表面法线和施加几何约束来改善扫描对齐，而 LodoNet [20] 则使用基于关键点的姿态估计。像 VertexNet [21] 这样的无监督学习技术，通过建模姿态不确定性来提高在各种环境中的精度。这些方法旨在提升泛化性和鲁棒性，以补充传统的 LiDAR 技术。

尽管具有许多优点，LiDAR 纯惯性导航仍面临一些局限。在诸如隧道等无特征环境中，由于约束不足，点云配准变得不可靠。此外，LiDAR 的低帧率 (10–20 Hz) 使得其在捕捉快速运动动态方面效果不佳。为了解决这些问题，使用传感器融合与互补的模式来增强鲁棒性和计算效率。LiDAR-惯性导航是一种常用的方法，因为 IMU 提供的高频惯性测量可以以最小的延迟捕捉短期运动动态。

传感器融合方法可以根据每个传感器对位姿估计的贡献进行分类。在松散耦合的方法中，LiDAR 和 IMU 的测量数据是独立处理的，它们的输出会在后期阶段进行融合。这些方法提供了模块化和鲁棒性，但可能无法充分利用两个传感器的互补特性。例子包括 LOAM [3] 或 Lego-LOAM [5]。

另一方面, 紧耦合的方法直接将原始 IMU 和 LiDAR 测量值集成到相同的优化框架中, 从而实现连续的状态估计和更高的精度。像 LIO-SAM [1] 或 Faster-LIO [22] 这样的方法在特征稀疏的环境中表现良好, 其中 IMU 约束有助于保持可靠的位姿估计。

尽管基于 LiDAR 的里程计有了进展, 仍有一些挑战阻碍其性能。其中一个主要问题是处理密集点云的高计算成本, 这使得在硬件受限的平台上难以高效地执行配准和优化算法。另一个显著的挑战是在同质环境或重复几何中提取可辨别特征的困难, 这可能导致运动估计中的错误。在这种情况下, 不依赖特征提取而利用完整点云信息的直接里程计方法通常被认为是替代方案 [4] [18]。此外, 过滤和数据缩减策略必须在降低计算负载的需求与保存定位所需的关键信息之间取得平衡。

B. 距离场计算

体积映射和同时定位与地图构建 (SLAM) 方法在机器人导航、规划和定位中对不同环境有显著贡献。这些方法主要利用离散体素结构、分层数据表示、概率模型和隐式神经表示。

基于体素的方法由于其简单和易于实现而被广泛使用。Voxblox [23] 有效地从截断符号距离场 (TSDF) 生成欧几里得符号距离场 (ESDF), 奠定了体积映射的共同基准。FIESTA [24] 通过采用基于占据的波前传播代替 TSDF, 进一步提高了计算效率, 从而降低了复杂性。此外, Voxfield [8] 通过输入点云数据的法线估计补充的非投影性 TSDF 融合提高了精度。尽管这些基于体素的解决方案因其流行性和 CPU 效率而受到欢迎, 但仍表现出固有的局限性, 如可扩展性问题和离散化误差, 从而降低了其在实时 SLAM 应用中的有效性和精确性。

已经提出层级数据结构, 如 OpenVDB [9], 以缓解可扩展性限制。利用 OpenVDB 的方法包括 VDB-EDT [25], 它通过高效的距离变换来表示 ESDF。虽然这些层级方法改进了可扩展性和内存使用, 但其离散性质仍然限制了平滑插值能力和连续优化。

隐式神经表示已经成为离散方法的连续替代方案, 提供密集且可微分的体积图。DeepSDF [26] 引入了一种基于神经网络的隐式模型来表示连续的 SDF。Continual Neural Mapping [27] 提出了使用重放缓冲区的增量神经方法, 但实时增量更新首次被 iSDF [11] 有效展示。最近, HIO-SDF [12] 引入了一种分层方法, 结合全球体素结构与局部激光雷达数据在线训练神经模型。TNDF-Fusion [28] 通过三角锥 TNDF 压缩城市规模的激光雷达地图, 而 NeRF-SLAM [29] 提供具有分层 NeRF 的实时密集单目 SLAM, 但它们没有在 CPU 上统一完整的 6 自由度激光雷达惯性导航与即时距离场映射。尽管取得了这些进展, 神经方法通常需要大量预训练、繁重的计算, 并且由于内存和推理限制, 仅限于小规模 SLAM。

高斯过程 (GP) 已被探索作为表示距离场的概率替代方法, 提供不确定性估计能力。以前的方法使用基于 GP 的模型进行不确定性感知的建图 [30], 但由于协方差矩阵的逆运算, 其推断仍然计算密集。为了解决计算限制, 采用了分层表示方法, 例如八叉树 [30]。VDB-GPDF [13] 利用嵌入在 OpenVDB 结构中的对数高斯过程, 生成具有不确定性测量的连续 ESDF。然而, 与 GP 推断相关的计算复杂性仍然是实时实施的重大障碍。

这些方法中的一个显著限制是它们主要用于映射任务的定向, 由于计算需求和离散化表示中固有的量化误差, 对实时 SLAM 的直接应用有限或根本没有。因此, 实时轨迹估计和增量地图更新仍然具有挑战性。

相比之下, 本文提出的方法直接激光雷达惯性里程计 (D-LIO) 明确针对这些局限性。D-LIO 通过消除对显式激光雷达特征选择和跟踪的需求, 简化了里程计流程。此外, 它使环境地图更新过程在恒定时间进行, 无论地图大小如何, 显著提高了可扩展性。通过将原始激光雷达点云数据直接融合到优化后的快速截断距离场 (Fast-TDF) 表示中, 我们的方法消除了通常将 TSDF 转换为 ESDF 所需的额外计算开销, 从而促进了实时集成到 SLAM 系统中。

距离场 (DFs) 能够为空间中的某个点提供最近的障碍物, 不管我们与障碍物的距离有多远。另一方面, 截断距离场 (TDFs) 仅在坐标在其截断距离内有障碍物时才有用。虽然这可能被视为 DFs 在定位方面的巨大优势, 但在实际中由于在点云配准过程中远点通常被异常值拒绝过程拒绝, 限制甚至消除了这种优势。因此, 如果根据手头的定位方法适当地调整截断距离, TDFs 可能成为距离场的非常有效的表示。

本文提出使用 TDF 来估计距离场。所提出的 Fast-TDF 利用二元掩码计算到每个障碍物影响区域的 L_1 距离。我们将看到如何使用二元掩码来编码 TDF 是非常方便的, 它将计算范式从对地图大小的依赖转换为对点云大小的依赖, 因此计算将取决于要包含在地图中的点的数量, 而不是地图的大小。

C. 二元核

我们的快速 TDF 使用二元内核来计算距离。该内核必须应用于每个被占用的单元格中的地图。结果, 它将生成周围空闲单元格在截断距离下到最近占用单元格的距离。内核表示从每个单元格到内核中心的占用单元格的 L_1 距离。内核中的距离按照这些惯例以位设置掩码表示 (图 1.(a) 显示了一个四个位的示例):

- 一个全部为零的掩码表示 L_1 距离为零。
- 从最低有效位 (LSB) 开始, 每个位的设置都代表两个连续单元之间的距离。
- 全一掩码表示最大 L_1 距离, 该距离等于掩码中的位数。

这种距离编码有一个很大的优点, 我们可以通过位与操作将任意集合的最短距离计算出来。不论涉及多少距离或值, 对所有距离进行位与操作将提供最短的值。这在三个层面上是积极的: i) 在计算机中, 位与操作可以非常快速地计算, 无论是标量还是向量化指令, ii) 我们完全不需要执行数值比较, 这会影响计算效率, iii) 距离插入的顺序不影响结果, 因为位与操作是可交换的, 这简化了并行处理。

作为一个说明性的例子, 假设我们有三个不同的距离值, 它们以 8 位的位集掩码表示, 这些值分别是 00111111 ($L_1 = 6$), 00001111 ($L_1 = 4$) 和 00000001 ($L_1 = 1$)。可以通过计算位与操作来轻松计算出这些值中最短的距离, 而无需进行数值比较:

$$00111111 \ \& \ 00001111 \ \& \ 00000001 = 00000001$$

图 1 展示了一个二维示例, 其中大小为 5×5 的两个二进制内核带有 4 位掩码编码, 分别以红色和蓝色单元格




Fig. 1: 使用 4 位编码的 5×5 二值核的二维示例。(a) 掩码与 L_1 距离之间的对应关系。(b) 输入点云在网格上的二维占用表示。(c) 通过对以每个占用单元为中心的重叠二值核进行按位与操作而得到的合并距离图。

为中心 (图 1.(b))。位掩码从内核中心的 0000 ($L_1 = 0$) 到角落的 1111 ($L_1 = 4$) 编码了 L_1 距离, 如图 1.(a) 所示。在图 1.(c) 中, 两个内核都使用按位与运算应用在各自己的中心周围。在重叠区域 (用黑色勾勒), 可以看到该方法如何保持到最近中心的最短距离。在应用二进制内核之前, 所有地图单元格都被初始化为 1111 (截断距离), 表示最大或未知距离。

D. TDF 网格地图

注意到, 之前的核实际上代表了其中心障碍物的 L_1 TDF。我们可以轻松地将一般点云的 TDF 计算为网格地图, 只需对包含点的每个单元中的这个核与网格地图执行按位与操作即可。以位集掩码形式表示距离, 隐含地解决了与距离场计算相关的所有问题。因此, 我们无需知道一个点是否接近任何其他点, 或是关键点在云中的评估顺序。

这种方法的另一个优点是易于并行化。原则上, 每个点都可以并行更新网格图, 然后通过按位与合并所有更新。我们可以利用这一特性来加速 TDF 的计算, 在 CPU 的不同线程中分配计算任务。

我们的 TDF 网格图将表示为一个固定分辨率的 3D 矩阵。网格的大小由 3D 点的空间分布决定。每个网格单元包含从该单元到 3D 地图最近点的 L_1 距离, 或当最近点较远时的截断距离。

截断距离将由三个因素定义: 用于表示位集掩码的位数、核的大小和网格分辨率。掩码的位数必须等于到核的最大 L_1 距离, 以提高方法的效率, 因此截断距离最终将由核的大小和分辨率决定。

E. 网格地图的初始化和访问

如前所述, 网格地图是一个 3D 矩阵, 其中包含空间中每个单元格的二进制掩码。每个单元格的位数由二进制掩码本身的大小决定。由于我们对世界有一个密集表示, 因此不建议使用如 kd-trees [31] 或 Octomap [32] 等稀疏表示。相反, 我们使用一个大型内存数组以固定分辨率表示空间。通过一个简单的哈希函数将 3D 坐标转换为数组中对应的索引 (具体细节见源代码)。这样, 访问网格所需的时间非常小, 更重要的是, 它是恒定的。

为了正确使用二进制内核按位与操作, 必须正确初始化这种网格地图。因此, 整个网格必须初始化为截断距




Fig. 2: D-LIO 工作流程。红色表示卡尔曼滤波器, 绿色表示 TDF 网格地图, 蓝色表示 LiDAR 预处理和优化。

离, 即所有位设置为 1 的掩码。一旦要存储到网格单元的值小于截断距离, 这个值将由二进制内核更新。

F. 距离计算

网格图存储的是二进制掩码, 而不是距离。我们需要一种方法来计算网格单元中二进制掩码实际的 L_1 距离。我们利用 C++ 的 `std::bitset()` 标准函数, 该函数直接映射到计算机汇编指令中。这个函数统计寄存器中已设置位的数量, 返回一个整数, 该整数即为对应的 L_1 距离。

G. 距离插值

根据 [33], 我们采用三线性插值来估计超出网格单元分辨率的距离场。三线性插值被用作计算和精度之间的权衡。因此, 三三次插值提供了更好的精度, 但其在每个网格单元中的计算负担阻碍了其在线使用。

使用三线性插值还提供了一种简单快捷的距离场梯度近似。鉴于这种梯度近似, 我们可以解析地计算关于第三方变量的复杂梯度, 例如用于定位的机器人位置或方向。与 [33] 相反, 此插值是在线计算的。

III. 直接 3D 激光雷达惯性里程计

图 2 显示了 D-LIO 方法的框图。该算法通过扩展卡尔曼滤波器 (EKF) 逐步估计系统位姿, 集成惯性测量用于位姿预测, 并通过点云到地图的配准进行位姿更新。因此, 对于每个传入的点云, 系统通过将其与基于截断距离场 (TDF) 进行映射的当前环境对齐来进行云配准, 使用 EKF 估计作为初始猜测。此对准用于通过状态更新来约束 EKF 的位姿和速度。每当估计的位姿变化超过预定阈值时, 就通过合并新信息来更新 TDF 地图。这

个更新后的地图随后在注册过程中促进了随后点云的更精确对准。

A. 惯性状态积分

根据 LiDAR 里程计算的常见做法 [34] [35]，可以使用惯性传感器来改善扫描之间的状态估计。惯性积分为 LiDAR 扫描对齐提供了良好的初始解决方案，这有利于后续的扫描匹配过程。此外，高频惯性积分能够实现 LiDAR 扫描去畸变，这也对扫描匹配过程的质量产生积极影响。我们使用一个带有以下状态向量的 EKF：

$$\mathbf{x} = [\mathbf{p}, \mathbf{v}, \mathbf{a}_b, \mathbf{r}, \mathbf{g}_b]^t \quad (1)$$

中，其中状态封装了三维位置 $\mathbf{p} = (x, y, z)$ 、线速度 $\mathbf{v} = (v_x, v_y, v_z)$ 、加速度计偏差 $\mathbf{a}_b = (a_{bx}, a_{by}, a_{bz})$ 、方向 $\mathbf{r} = (r_x, r_y, r_z)$ 和陀螺仪偏差 $\mathbf{g}_b = (g_{bx}, g_{by}, g_{bz})$ 。在这里，位置 $\mathbf{p}$ 、速度 $\mathbf{v}$ 和方向 $\mathbf{r}$ 用全局坐标系表示，而加速度计和陀螺仪偏差，分别为 $\mathbf{a}_b$ 和 $\mathbf{g}_b$ ，用局部惯性坐标系表示。

在预测步骤中，滤波器集成了 IMU 测量（角速度和线性加速度）以传播状态向前推进。当接收到新的 LiDAR 扫描后，使用高频惯性状态估计进行去畸变，以补偿扫描获取过程中累计的运动引起的扭曲。随后，使用从点云注册步骤中获得的精炼姿态和从连续点云位置推导出的估计速度进行更新步骤。

B. 激光雷达点云配准

这个点云配准被表述为 SE(3) 空间上的一个非线性优化问题，其目标是最小化每个点到地图中最近物体的距离。点云根据 EKF 的当前状态进行预变换，因此配准只需要处理扫描之间惯性集成的累积误差。

该问题被表述为以下残差和的最小化：

$$\min_{\mathbf{t}, \mathbf{q}} \sum_i \rho_i L_1(\mathbf{R}(\mathbf{q}) \cdot \mathbf{p}_i + \mathbf{t})^2 \quad (2)$$

，其中 i 对应于点云中的每一个点， $\mathbf{t} \in \mathbb{R}^3$ 是平移向量， $\mathbf{q} \in \mathbb{H}$ 是编码旋转的单位四元数， $\mathbf{R}(\mathbf{q})$ 是对应的旋转矩阵， ρ_i 是详见于第 ?? 节的鲁棒核， $L_1(\cdot)$ 利用截至目前已计算出的 TDF 在 Sections II-F 和 II-G 中所述的三线性插值返回到最近物体的无符号 L_1 距离。

优化是使用 Ceres Solver 库 [36] 进行的。为了正确处理四元数的单位范数约束，应用了适当的李群公式及其相应的李代数，从而能够在切空间中进行优化。

在构建优化问题之前，落在 TDF 网格之外的点会被舍弃，以确保距离评估的有效性。对于剩余的点，应用一个稳健的损失函数，以减轻离群点的影响，同时保持估计的全局一致性。特别地，采用了柯西损失，其尺度参数是该点到传感器距离的函数：

$$\rho_i = \text{CauchyLoss}(\lambda \cdot (0.1 + 0.1 \cdot \|\mathbf{p}_i\|)) \quad (3)$$

，其中 λ 是一个调节因子， $\|\mathbf{p}_i\|$ 表示以 LiDAR 传感器系统参考系表达的三维点 $\mathbf{p}_i$ 的欧几里得范数。

这种稳健核确保由于较高残差导致的远点不会被过度惩罚，这种情况可能自然发生于小的方向误差。例如，仅仅 1° 的旋转误差可能会在附近点（例如，几厘米）产生可以忽略的位移，但在远处点可能导致显著的偏差（例如，几米）。如果使用固定尺度的稳健损失，这些远处的

点可能会被视为异常值并在优化过程中被忽略，导致系统收敛到局部最优但全局不准确的解决方案。提议的核函数则保留了近点和远点的贡献，促进整个云的稳健收敛。

C. 关键帧和地图更新

一种基于关键帧的方法用于地图更新，当相对于前一个关键帧的相对平移或旋转超过预定义阈值 t_{th} 和 q_{th} 时，分别创建一个新的关键帧。当创建新关键帧时，通过整合当前点云来更新 TDF 地图，首先根据最新优化的姿态估计变换点云，确保在融合前在全局框架中正确对齐。此过程在第 ?? 节中详细描述，通过对以每个点为中心的核执行按位与操作进行 TDF 网格更新，将其从变换后的点云中集成到网格中，同时考虑新点和现有地图数据。尽管这是系统中计算最密集的阶段，但按位与操作和并行化的使用有助于优化地图更新过程，并显著减少处理时间。

IV. 实验结果

该算法已经在两个数据集上进行了测试，即 VIRAL 数据集 [37] 和 Newer College 数据集 [38]，以评估其在使用各种轨迹的情况下正确定位的能力，这些轨迹对其性能构成挑战。

里程估计的准确性主要通过 VIRAL 数据集得到验证，因为它包含更具挑战性的环境，包括树木、反射或透明的表面以及测试算法稳定性的复杂空中轨迹。另一方面，在 Newer College 数据集中，正确的网格生成已经在显著更大的环境中进行评估，以展示算法在地图大小和点数方面的可扩展性。一个补充视频展示了定性结果和 3D 重建。¹

在这两个数据集中，通过将估计的轨迹与真实轨迹进行比较，计算了绝对平移误差 (ATE)。我们使用 VIRAL 数据集提供的基准工具以确保一致且可靠的轨迹评估。

在表格 I 中展示了在两个数据集上获得的结果，并与其他方法进行比较，如 A-LOAM [39]、M-LOAM [40]、FAST-LIO2 [35]、KISS-ICP [2] 和 LIO-SAM [1]。A-LOAM、M-LOAM 和 LIO-SAM 的指标取自 VIRAL-SLAM 论文 [41]，而 KISS-ICP 的指标取自 [42]。LIO-SAM 在 quad-easy 序列中的结果取自 NV-LIOM [43]。请注意，LIO-SAM 执行后端优化，这使得与纯里程计的比较不完全公平。然而，我们包含了其结果以证明我们的方法尽管不使用后端优化，仍能实现可比的性能。正如表 I 所示，我们的方法在大多数序列中达到最低的 ATE，并在其余序列中排名第二，突出了其在各种复杂轨迹下的一贯准确性和鲁棒性。

这些实验结果使用了配置为 $40 \times 40 \times 40$ 二进制内核的 FastTDF，并采用 64 位掩码编码。结合 0.05 米的网格分辨率，该内核的截断距离约为 3 米。

A. VIRAL 数据集

我们的算法已经在序列“eee”、“nya”和“sbs”上进行了测试，每个序列包含三个子轨迹。这些序列涵盖了各种环境，包括室内和封闭空间、具有不同建筑高度的开放区域以及对激光雷达测距具有挑战性的表面，例如玻璃和半透明材料。

¹<https://youtu.be/iIVCYR85AHg>

用于记录此数据集的载具是配备有多个传感器的 DJI M600 六旋翼无人机, 包括 IMU “VectorNav VN100” 和水平与垂直激光雷达 “Ouster OS1-16 gen 1”, 组合后的点云密度约为每帧 20 千点。在这些实验中, 地图大小设置为 $60 \times 60 \times 25$ 米, 参数为 $\lambda = 1.0$ 、 $t_{th} = 2\text{m}$ 和 $q_{th} = 25^\circ$ 。

图 3 显示了使用 D-LIO 生成的 3D 重建及获取它的轨迹。更全面的成果, 包括所有运行的估计轨迹及相关可视化, 将在相应的 GitHub 仓库²中提供。

在这个数据集中, 遵循了 “Quad-Easy” 轨迹, 其包括在四边形区域内进行两圈行走, 行走速度为标称速度。平台配备了一系列传感器, 我们只使用了带有集成 IMU 的 LiDAR “Ouster OS-0-128”, 因为惯性信息也来自 LiDAR 中集成的 IMU。在这种情况下, 平台由一个人手动携带, 该人在环境中以恒定速度执行几圈实验。对于这些实验, 地图大小设置为 $80 \times 60 \times 35$ 米, 参数为 $\lambda = 1.0$ 、 $t_{th} = 1\text{m}$ 和 $q_{th} = 25^\circ$ 。

如图 4 所示, 所跟踪的轨迹相对简单, 并且 D-LIO 成功估计出一个可与表 I 中列出的顶尖方法所达到的值相媲美的结果。该环境的特殊性在于其大规模 (约 $80 \times 60 \times 35$ 米) 和 LiDAR 传感器的高点密度, 约 100k 点每帧。测试此数据集的目的是观察算法在高点密度环境中的可扩展性, 因为现有使用距离场生成的里程计算法在这种可扩展性上存在困难。

B. 运行时和内存消耗

实验是在一台配备 32GB 内存和第 13 代英特尔 Core i7-13700H 处理器的 HP Victus 16 笔记本电脑上进行的。实验中未使用 GPU。该系统的性能是通过分析内存使用、CPU 负载和两个数据集的执行时间来评估的, 两个案例中都使用相同的配置。关于内存消耗, college 数据集的占用量范围从 30 % 到 90 %, 而在 VIRAL 数据集中, 内存使用通常较低, 在 10 % 到 40 % 之间。在这两种情况下, 网格更新步骤是内存使用的主要贡献者。

总体内存消耗主要由所选地图的大小决定, 因为网格保留了一部分固定的内存。因此, 在大学数据集上的实验消耗了大约 19 GB 的内存, 而在较小地图的 VIRAL 上的实验则需要大约 10 GB。

执行时间汇总在表格 II 中, 报告了在没有降采样的情况下测量的多个轨迹的平均时间, 从而反映了最具挑战性的场景。地图更新步骤一贯是最耗计算资源的阶段, 通常成为算法的瓶颈。此更新时间强烈依赖于要整合的点云密度。例如, 在 VIRAL 数据集中, 来自水平和垂直 OS-1 的较低密度点 (每次扫描约 20k 点) 导致地图更新时间较短 ($\approx 0.30\text{s}$), 而在学院数据集中, LiDAR 每次扫描产生约 100k 点, 更新步骤显著更慢 ($\approx 1.2\text{s}$)。然而, 地图更新时间对平均总时间几乎没有影响 (见表 II), 因为我们的方法以远低于传感器采集频率 (10 Hz) 的频率执行更新操作, 而优化步骤在每次扫描时执行, 保持轻量级 (通常低于 0.05s)。这种设计使得每次扫描的总体平均计算时间在大多数情况下保持低于 LiDAR 速率, 除了在学院数据集中, 由于高点密度和较长运动间隔期间的频繁更新, 导致更高的总运行时间。

同样值得注意的是, 最新的距离场映射方法, 例如 VDB-GPDF [13], 仅专注于重建, 报告的执行时间与我

们的相似, 但我们的方法同时执行里程计和重建, 而且没有任何降采样。虽然地图更新频率较低, 平均一米更新一次, 但它整合了全分辨率点云, 提供了计算效率和映射精度之间的平衡。

V. 结论和未来工作

D-LIO, 是一种基于快速-TDF 同时映射的全直接 LiDAR-惯性里程计流程, 已显示出能够匹配或超越基于特征的先进方法, 同时为后续任务生成连续可用的距离场。与传统 TSDF/ESDF 框架的更新成本随着地图体积增长不同, 我们的 Fast-TDF 二元掩码方案仅将每个积分步骤与传入点的数量相联系。通过在截断距离场中直接编码障碍物的接近, 我们避免了特征提取, 即使在特征稀少或高反射环境中也能实现稳健的收敛。生成的 TDF 可立即用于碰撞规避或规划, 无需任何后处理。

未来的工作将集中在两个主要的扩展上。首先, 解决使用固定大小网格的限制, 因为目前还没有策略来管理系统接近其空间限制时的地图。引入动态调整大小或移动方法, 可能会提高在较大环境中的可扩展性。其次, 扩展 Fast-TDF 内核以支持符号距离估计, 使系统能够区分一个点是在障碍物的前面还是后面, 从而可能提高精度。

References

- [1] T. Shan, B. Englot, D. Meyers, W. Wang, C. Ratti, and R. Daniela, “Lio-sam: Tightly-coupled lidar inertial odometry via smoothing and mapping,” in IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), IEEE, 2020, pp. 5135–5142.
- [2] I. Vizzo, T. Guadagnino, B. Mersch, L. Wiesmann, J. Behley, and C. Stachniss, “Kiss-icp: In defense of point-to-point icp simple, accurate, and robust registration if done the right way,” IEEE Robotics and Automation Letters, vol. PP, pp. 1–8, 02 2023.
- [3] J. Zhang and S. Singh, “Loam: Lidar odometry and mapping in real-time,” Robotics: Science and Systems Conference (RSS), pp. 109–111, 01 2014.
- [4] K. Chen, B. T. Lopez, A.-a. Agha-mohammadi, and A. Mehta, “Direct lidar odometry: Fast localization with dense point clouds,” IEEE Robotics and Automation Letters, vol. 7, no. 2, pp. 2000–2007, 2022.
- [5] T. Shan and B. Englot, “Lego-loam: Lightweight and ground-optimized lidar odometry and mapping on variable terrain,” 10 2018, pp. 4758–4765.
- [6] H. Wang, C. Wang, C.-L. Chen, and L. Xie, “F-loam: Fast lidar odometry and mapping,” in 2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2021, pp. 4390–4396.
- [7] A. Segal, D. Hähnel, and S. Thrun, “Generalized-icp,” 06 2009.
- [8] Y. Pan, Y. Kompis, L. Bartolomei, R. Mascaro, C. Stachniss, and M. Chli, “Voxfield: Non-projective signed distance fields for online planning and 3d reconstruction,” in 2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2022, pp. 5331–5338.
- [9] K. Museth, “Vdb: High-resolution sparse volumes with dynamic topology,” ACM Trans. Graph., vol. 32, pp. 27:1–27:22, 07 2013.
- [10] B. Curless and M. Levoy, “A Volumetric Method for Building Complex Models From Range Images,” in Proceedings of the 23rd Annual Conference on Computer Graphics and Interactive Techniques - SIGGRAPH '96. ACM Press, 1996.
- [11] J. Ortiz, A. Clegg, J. Dong, E. Sucar, D. Novotny, M. Zollhoefer, and M. Mukadam, “isdf: Real-time neural signed distance fields for robot perception,” 2022. [Online]. Available: <https://arxiv.org/abs/2204.02296>
- [12] V. Vasilopoulos, S. Garg, J. Huh, B. Lee, and V. Isler, “Hio-sdf: Hierarchical incremental online signed distance fields,” 2024. [Online]. Available: <https://arxiv.org/abs/2310.09463>

²<https://anonymous.4open.science/r/D-LIO>

TABLE I: 在 VIRAL 和 New College 数据集上，不同算法的实验结果，ATE（米）。最好的结果用粗体突出显示，第二好的结果是 underlined，除去 LIO-SAM，因为它执行后端优化。

	D-LIO	A-LOAM	M-LOAM	FAST-LIO2	KISS-ICP	LIO-SAM
eee01	0.092	0.212	0.249	<u>0.166</u>	2.383	0.075
eee02	0.083	0.199	0.168	<u>0.100</u>	1.586	0.069
eee03	0.122	0.148	0.233	<u>0.142</u>	1.055	0.101
nya01	<u>0.080</u>	0.077	0.123	0.127	0.359	0.076
nya02	<u>0.104</u>	0.091	0.191	0.151	-	0.07
nya03	0.065	<u>0.108</u>	0.226	0.130	1.389	0.137
sbs01	0.094	<u>0.103</u>	0.173	0.130	1.353	0.089
sbs02	0.061	<u>0.091</u>	0.147	0.144	1.435	0.083
sbs03	0.098	0.367	0.153	0.126	<u>1.037</u>	0.14
quad-easy	<u>0.093</u>	0.085	0.141	0.100	<u>0.100</u>	0.074




Fig. 3: “eee”、“nya” 和 “sbs” 地图的 3D 地图重建以及每个估计的 2D 轨迹，其中地面实况显示为红色，估计的轨迹为蓝色。




Fig. 4: 来自 Newer College Dataset 的地图 “Quad-Easy” 的三维地图重建及其估计轨迹。

TABLE II: 对不同数据集的运行时间分析，显示每个处理阶段的平均值 $\pm$ 标准差（以秒为单位）。

Dataset	Total (s)	Optimize (s)	Update (s)
college	0.583 ± 0.433	0.430 ± 0.187	1.216 ± 0.060
eee	0.052 ± 0.051	0.040 ± 0.015	0.301 ± 0.036
nya	0.083 ± 0.071	0.065 ± 0.024	0.367 ± 0.022
sbs	0.051 ± 0.048	0.044 ± 0.016	0.301 ± 0.014

- [13] L. Wu, C. L. Gentil, and T. Vidal-Calleja, “Vdb-gpdf: Online gaussian process distance field with vdb structure,” 2024. [Online]. Available: <https://arxiv.org/abs/2407.09649>
- [14] P. Besl and N. D. McKay, “A method for registration of 3-d

- shapes,” IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 14, no. 2, pp. 239–256, 1992.
- [15] P. Biber and W. Strasser, “The normal distributions transform: a new approach to laser scan matching,” in Proceedings 2003 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS 2003) (Cat. No.03CH37453), vol. 3, 2003, pp. 2743–2748 vol.3.
- [16] P. Dellenbach, J.-E. Deschaud, B. Jacquet, and F. Goulette, “Ct-icp: Real-time elastic lidar odometry with loop closure,” in 2022 International Conference on Robotics and Automation (ICRA), 2022, pp. 5580–5586.
- [17] J.-E. Deschaud, “Imls-slam: Scan-to-model matching based on 3d data,” in 2018 IEEE International Conference on Robotics and Automation (ICRA), 2018, pp. 2480–2485.
- [18] X. Chen, A. Milioto, E. Palazzolo, P. Giguère, J. Behley, and C. Stachniss, “Suma++: Efficient lidar-based semantic slam,” 11 2019, pp. 4530–4537.
- [19] Q. Li, C. Shaoyang, C. Wang, X. Li, C. Wen, M. Cheng, and J. Li, “Lo-net: Deep real-time lidar odometry,” 06 2019, pp. 8465–8474.
- [20] C. Zheng, Y. Lyu, M. Li, and Z. Zhang, “Lodonet: A deep neural network with 2d keypoint matching for 3d lidar odometry estimation,” in Proceedings of the 28th ACM International Conference on Multimedia, ser. MM ’20. ACM, Oct. 2020, p. 2391–2399. [Online]. Available: <http://dx.doi.org/10.1145/3394171.3413771>
- [21] Y. Cho, G. Kim, and A. Kim, “Unsupervised geometry-aware deep lidar odometry,” in 2020 IEEE International Conference on Robotics and Automation (ICRA), 2020, pp. 2145–2152.
- [22] C. Bai, T. Xiao, Y. Chen, H. Wang, F. Zhang, and X. Gao, “Faster-lio: Lightweight tightly coupled lidar-inertial odome-

- try using parallel sparse incremental voxels,” *IEEE Robotics and Automation Letters*, vol. 7, pp. 4861–4868, 04 2022.
- [23] H. Oleynikova, Z. Taylor, M. Fehr, R. Siegwart, and J. Nieto, “Voxblox: Incremental 3d euclidean signed distance fields for on-board mav planning,” in *2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE, sep 2017, p. 1366–1373. [Online]. Available: <http://dx.doi.org/10.1109/IROS.2017.8202315>
 - [24] L. Han, F. Gao, B. Zhou, and S. Shen, “Fiesta: Fast incremental euclidean distance fields for online motion planning of aerial robots,” 2019. [Online]. Available: <https://arxiv.org/abs/1903.02144>
 - [25] D. Zhu, C. Wang, W. Wang, R. Garg, S. Scherer, and M. Q. H. Meng, “Vdb-edt: An efficient euclidean distance transform algorithm based on vdb data structure,” 2021. [Online]. Available: <https://arxiv.org/abs/2105.04419>
 - [26] J. J. Park, P. Florence, J. Straub, R. Newcombe, and S. Lovegrove, “DeepSDF: Learning continuous signed distance functions for shape representation,” 2019. [Online]. Available: <https://arxiv.org/abs/1901.05103>
 - [27] Z. Yan, Y. Tian, X. Shi, P. Guo, P. Wang, and H. Zha, “Continual neural mapping: Learning an implicit scene representation from sequential observations,” 2021. [Online]. Available: <https://arxiv.org/abs/2108.05851>
 - [28] Z. Chen, K. Zhang, H. Chen, M. Y. Wang, W. Zhang, and H. Yu, “Tndf-fusion: Implicit truncated neural distance field for lidar dense mapping and localization in large urban environments,” *IEEE Robotics and Automation Letters*, vol. 9, no. 9, pp. 7445–7452, 2024.
 - [29] A. Rosinol, J. J. Leonard, and L. Carlone, “Nerf-slam: Real-time dense monocular slam with neural radiance fields,” 2022. [Online]. Available: <https://arxiv.org/abs/2210.13641>
 - [30] C. L. Gentil, O.-L. Ouabi, L. Wu, C. Pradalier, and T. Vidal-Calleja, “Accurate gaussian-process-based distance fields with applications to echolocation and mapping,” 2023. [Online]. Available: <https://arxiv.org/abs/2302.13005>
 - [31] M. Skrodzki, “The k-d tree data structure and a proof for neighborhood computation in expected logarithmic time,” 2019. [Online]. Available: <https://arxiv.org/abs/1903.04936>
 - [32] K. Wurm, A. Hornung, M. Bennewitz, C. Stachniss, and W. Burgard, “Octomap: A probabilistic, flexible, and compact 3d map representation for robotic systems,” vol. 2, 01 2010.
 - [33] F. Caballero and L. Merino, “DLL: Direct LIDAR Localization. A map-based localization approach for aerial robots,” in *IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2021.
 - [34] Y. Wu, T. Guadagnino, L. Wiesmann, L. Klingbeil, C. Stachniss, and H. Kuhlmann, “Lio-ekf: High frequency lidar-inertial odometry using extended kalman filters,” in *2024 IEEE International Conference on Robotics and Automation (ICRA)*, 2024, pp. 13 741–13 747.
 - [35] W. Xu, Y. Cai, D. He, J. Lin, and F. Zhang, “Fast-lio2: Fast direct lidar-inertial odometry,” 2021. [Online]. Available: <https://arxiv.org/abs/2107.06829>
 - [36] S. Agarwal, K. Mierle, and T. C. S. Team, “Ceres Solver,” 10 2023. [Online]. Available: <https://github.com/ceres-solver/ceres-solver>
 - [37] T.-M. Nguyen, S. Yuan, M. Cao, Y. Lyu, T. H. Nguyen, and L. Xie, “Ntu viral: A visual-inertial-ranging-lidar dataset, from an aerial vehicle viewpoint,” *The International Journal of Robotics Research*, vol. 41, no. 3, pp. 270–280, 2022.
 - [38] L. Zhang, M. Camurri, D. Wisth, and M. Fallon, “Multi-camera lidar inertial extension to the newer college dataset,” 2021.
 - [39] T. Wang, X. Wu, H. Yang, P. Zhao, and Q. Hu, “An improved a-loam 3d mapping method based on ultra-wide field angle of multi-line lidar,” in *2022 29th International Conference on Geoinformatics*, 2022, pp. 1–6.
 - [40] J. Jiao, H. Ye, Y. Zhu, and M. Liu, “Robust odometry and mapping for multi-lidar systems with online extrinsic calibration,” *IEEE Transactions on Robotics*, vol. PP, pp. 1–10, 05 2021.
 - [41] “Viral slam: Tightly coupled camera-imu-uwb-lidar slam,” 05 2021.
 - [42] J. L. Blanco-Claraco, “A flexible framework for accurate lidar odometry, map manipulation, and localization,” 2024. [Online]. Available: <https://arxiv.org/abs/2407.20465>
 - [43] D. Chung and J. Kim, “Nv-liom: Lidar-inertial odometry and mapping using normal vectors towards robust slam in multifloor environments,” *IEEE Robotics and Automation Letters*, vol. 9, no. 11, pp. 9375–9382, 2024.