

FlashBack：一致性模型加速的 共享自主性

Luzhe Sun, Jingtian Ji, Xiangshan Tan, Matthew R. Walter
Toyota Technological Institute at Chicago, United States
{ luzhesun, jjingtian, vincenttann, mwalter } @ttic.edu

Abstract: 共享自主技术是一种使用户能够控制机器人技术的辅助技术，如果没有这种技术，用户几乎不可能直接控制机器人。然而，标准方法做出了一些假设，这些假设限制了它们在实际中的应用——例如，用户目标的先验知识或者他们希望优化的目标（即奖励）函数的知识、用户政策的知识，或在训练期间对用户的查询级访问。基于扩散的共享自主方法不做这些假设，而是只需要获得期望行为的示范，同时允许用户保持控制权。然而，这些优势是以高计算复杂性为代价的，这使得实时共享自主几乎是不可能的。为克服这一限制，我们提出了一种名为一致性共享自主（CSA）的共享自主框架，该框架采用基于一致性模型的扩散公式。CSA 的关键是它使用常微分方程（PF ODE）的蒸馏概率流，以一步生成高保真样本。这导致了推理速度显著快于以前基于扩散的共享自主方法，从而在复杂领域中实现了实时辅助，仅需进行一次函数评估。此外，通过在 PF ODE 的中间状态对有缺陷的行为进行干预，CSA 能够实现不同程度的辅助。我们在各种具有挑战性的模拟和现实世界机器人控制问题上评估 CSA，在任务性能和计算效率方面都显著优于现有的最先进方法。我们的代码可在 <https://ripl.github.io/CSA-website/> 获取。

Keywords: Consistency Model, Shared Autonomy, ODE Distillation

1 介绍

共享自治是一种协作控制范式，其中由人类操作员和自主代理共同控制机器人系统以实现共同目标 [1, 2, 3, 4, 5]。通过将人类的直觉与机器的精确性结合，共享自治提高了性能，确保了安全性，并减少了操作员的工作负荷。这在复杂的控制场景中特别有价值，因为它使人类驾驶员能够提供高层次的输入，而机器人副驾驶则自主管理低层次的运动校正，以维护安全性和操作效率 [6, 7, 8, 9, 10, 11]。

传统上，共享自主算法假设存在一组已知的固定目标，通过用户的输入在测试时推断其目标 [12, 13, 14, 15]。虽然这些方法在某些环境中是有效的，但在目标空间未明确定义的非结构化和半结构化环境中会有困难。生成建模的最新进展，特别是扩散概率模型，在图像、音频和 3D 生成等领域取得了革命性进展 [16, 17, 18, 19, 20, 21, 22, 23, 24]，为解决这些挑战提供了一个有前景的途径，通过将共享自主性框定为从学得的行为分布中进行采样 [25, 1, 26]。

在共享自主性方面，基于扩散的方法在不对目标空间做显性假设的情况下，已被证明能有效稳定用户的操作。例如，Yoneda et al. [1] 引入了带噪声注入的部分扩散以保持用户意图，而 Yin et al. [27] 使用运动梯度作为具有丰富上下文的操作任务的去噪指导。然而，由于扩散过程的计算成本，将扩散模型应用于实时机器人领域仍然具有挑战性。扩散-去噪概率模型（DDPMs）[16] 通过去噪过程解决了逆向时间随机微分方程（SDE），但此过程通常需要数百步。这可能导致生成/推理的时间复杂度过高，妨碍实时应用。此外，用于共享自主性的 DDPMs 倾向于生成可能忽略用户提供的信息的样本。因此，迫切需要尊重用户输入的实时共享自主快速生成方法。

一致性模型（CM）[28] 已成为解决这些问题的一种引人注目的解决方案。与传统扩散模型中迭代去除噪声的方式不同，CM 直接学习一个去噪函数以高效“跳跃”到高质量结果。利用从 EDM 模型 [18] 中预训练的基于常微分方程（ODE）的概率流，CM 有效地将复杂




Figure 1: 使用我们提出的一致性共享自主 (CSA) 算法的结果与基于 DDPM 的共享自主基准在三个具有挑战性的控制任务中的可视化比较。

的 ODE 流提炼为快速的单步（或少步）生成过程，而不牺牲真实度。图像合成中的实证成果展示了效率的显著提升。值得注意的是，Song et al. [28] 展示了与标准扩散方法相比，使用明显更少的采样迭代就达到了最先进的图像生成性能。同样，应用于机器人规划中的一致性策略在保持竞争性能的同时，实现了比传统基于 DDPM 的方法快多达 100 倍的推理速度 [29, 25]。

受部分扩散作为平衡用户控制与任务性能的手段的启发 [1, 30] 以及基于常微分方程 (ODE) 的蒸馏方法的计算效率 [28]，我们提出了一种用于共享自治的一致性模型 (CSA，如图 1 所示)。与当代的共享自治方法不同，CSA 提供了加速推理，确保接近最近的专家动作，并且只需最少的训练数据。我们在一系列模拟和真实世界的控制任务中评估了 CSA，展示了其相较于以往最先进技术的改进。

2 相关工作

早期关于共享自治的研究假设用户目标的先验知识 [31, 32]，或认为它可以通过用户输入显式推断 [33, 12, 13, 14, 15]。Reddy et al. [7] 引入了无模型深度强化学习 (RL) 用于共享自治，消除了对已知环境动态的需求；后续的研究进一步发展了这一方法 [8, 34]。基于扩散模型的动作规划在策略学习 [25, 35, 29] 和共享自治中已被证明是强大的。Yoneda et al. [1] 提出了一种部分扩散机制，该机制对用户的动作添加噪声，然后采用部分反向扩散过程将动作精炼至训练分布，从而在纠正动作（符合性）的同时保留用户意图（忠实度）。然而，在这种基于 SDE 的模型中，每个反向步骤注入新鲜噪声是一把双刃剑：它增加了多样性，但可能将结果推进到不理想的模式中。DexterityGen (DexGen) [27] 采取了不同的方法，放弃部分扩散，转而采用用户动作促进策略，以找到与用户意图一致的轨迹。

尽管有这些进展，以上两种基于扩散的方法（使用 DDPM 或 DDIM 公式）都受到迭代推断的限制。相比之下，CSA 采用了一种一步推断范式，这使得微秒级生成成为可能，仅需少量训练数据，不依赖于显式的用户目标预测，却在高精度任务中表现出色。与上述标准扩散公式（例如，DDPM [16]）相比，去噪扩散隐式模型 (DDiM) [17] 将逆过程重塑为一个确定性常微分方程 (ODE)。EDM [18] 通过改进的预设和步骤加权统一了 SDE 和 ODE 的采样。特别是，基于 ODE 的采样使样本沿着理想去噪路径达到其最近邻，这一保证是基于 SDE 的扩散所缺乏的。然而，尽管加速了采样，但过于激进地减少步骤数仍可能降低输出质量。

蒸馏技术已被探索用于进一步降低推理成本 [36, 37]。这些方法通常涉及训练一个基于常微分方程 (ODE) 的教师模型，以生成详细的高质量轨迹，然后再训练一个学生模型，学习以更少的中间步骤近似这些轨迹。例如，Song et al. [28] 提出的一致性模型 (CM)，利用 ODE 轨迹中固有的自治性。给定沿同一轨迹的两个不同的中间状态 $\{x^u, x^v\}$ ，一致性模型强制预测收敛到相同的干净目标 $\hat{x}_0$ 。通过优化这种一致性，一致性模型可以在少至一步或多步推理中快速采样，显著提高效率而不牺牲生成质量。

我们提出的方法的基础是将共享自治形式化为一个生成过程，通过该过程，我们从一个学习到的专家分布中采样动作，这些动作与用户的潜在意图一致。扩散模型提供了一种吸引人的方式来生成这些样本，因为用户提供的动作可以被视为通过反向扩散遍历的轨迹上的噪声输入（我们请读者参考附录 4.1 了解概率流常微分方程的讨论）。这是我们在这里采用




Figure 2: EDM (教师) 模型的训练过程。




Figure 3: CSA (学生) 模型的训练过程。

的方法。然而，正如我们之前所讨论的，这个反向扩散过程的计算成本阻碍了共享自治所需的实时操作。

与其依赖许多顺序去噪步骤，CSA 使用一致性模型蒸馏将基于 ODE 的扩散轨迹完全融合成一个高效的步骤。具体来说，我们首先通过迭代解决 PF ODE 来训练一个高保真度的教师扩散模型，这一过程能够产生可靠的样本，但需要几十个或更多的求解步骤。在蒸馏过程中，我们训练一个学生模型，以直接从教师的初始噪声输入学习到最终的干净输出。实际上，学生模型“跳过”了中间的流动轨迹，一次性地用单次前向传递（或极少的步骤）近似教师的多步骤优化，同时保持可比的样本质量。

我们通过将状态预测集成到 EDM 框架中以充当教师模型的方式来训练我们的 CSA 模型。随后，基于一致性模型 (CM) 的去噪器 CSA 从该教师中提取 ODE 流知识进行进一步去噪，从而显著加速推理过程。

训练数据由状态-动作-下一状态转换 \$(s, a, s_n)\$ 组成，其中 \$s\$ 是当前状态，\$a\$ 是专家动作，\$s_n\$ 是下一状态。我们将状态预处理为两个条件，\$cond_1 = s\$ 和 \$cond_2 = \frac{s_n - s}{\|s_n - s\|_2}\$，其中后者衡量状态变化的方向，作为短期用户意图的指示。在训练过程中，我们可以仅以 \$\{cond_1\}\$ 或联合以 \$\{cond_1, cond_2\}\$ 作为条件。遵循 EDM 框架，我们使用 Karras 采样器 [18] 来划分噪声计划 \$\{\sigma^0, \dots, \sigma^t\}\$。在噪声步骤 \$t\$，我们通过注入噪声 \$\sigma^t \cdot z, z \sim \mathcal{N}(0, 1)\$ 获得扰动动作 \$a^t\$。超参数 \$\{c_{in}, c_{out}, c_{skip}\}\$ 是噪声 \$\sigma^t\$ 的函数（附录 4.3）。我们使用联合条件去噪器 \$D(\cdot)\$ 来去除噪声（图 2）。模型使用与动作嵌入相同的隐藏维度嵌入所有条件 \$\{Cond_1, Cond_2, t\}\$，将它们求和，然后传递到一个三层 MLP 中以预测输出 \$O\$。每一层通过残差连接合并条件嵌入。

$$O = F_\theta(c_{in} \cdot a^t, t, cond_1, \text{Optional}(cond_2)) \quad (1a)$$

$$D = c_{out} \cdot O + c_{skip} \cdot a^t \quad (1b)$$

引入了一个可学习的自适应加权模型 \$\lambda(\cdot)\$ 来跟踪 EDM \$\mathcal{L}_{EDM}(\theta) = \mathbb{E}_{(t, a, a^t | a)}[\text{dist}(\lambda(\sigma^t), a, D(\cdot)))]\$ 中的损失，其中我们使用条件损失和联合条件损失来跟踪 \$\{cond_1\}\$ 和 \$\{cond_1, cond_2\}\$ 情境的训练指标，在计算损失时，我们以概率 \$\gamma\$ 丢弃 \$Cond_2\$。

EDM 模型推断也使用离散的数值求解器；因此，其递归过程仍然缓慢。推断时，真实的下一个状态 \$s_n\$ 在未执行预测动作 \$\hat{a}\$ 的情况下无法被观察到。为了解决这个问题，我们同时训练一个前向模型 \$\Phi(s, a) \mapsto \hat{s}_n\$，使用带有归一化层的 MLP 来实现。




Figure 4: 环境设置

学生模型 如图 ?? 所示，蒸馏训练策略涉及在同一个 PF ODE 轨迹上找到两个样本 $\{a^i, a^j\}, i, j \in \{0, \dots, T\}$ ，学习一个学生去噪器 $f(a^t, t, o^t) \mapsto \hat{a}^0$ ，其中 o^t 表示包括 $\{c_{in}^t, c_{out}^t, c_{skip}^t, \text{cond}_1, \text{cond}_2, \sigma^t\}$ 在内的所有其他条件。我们将去噪过程 $\{a^i, a^j\}$ 表示为 $f(a^i, i, o^i) \mapsto \hat{a}^{i0}$ ， $f(a^j, j, o^j) \mapsto \hat{a}^{j0}$ 。由于轨迹是确定性的 ODE 流动，它们应追溯到同一个起点。然后，我们可以将目标公式化为最小化它们之间距离的目标，即 $\min \text{MSE}(\hat{a}^{i0}, \hat{a}^{j0})$ 。

在实践中，我们选择 $i = j - 1$ ，并在以下表达式中使用 t 和 $t - 1$ 。挑战在于从同一流中采样 a^t 和 a^{t-1} 。我们从专家动作 a^0 开始，注入噪声 $\sigma^t \cdot z$ 以获得 a^t 。为了在同一流上获得 a^{t-1} ，我们将使用教师模型 $g(\cdot)$ （预训练的 EDM 去噪器）以及一个 Huen 求解器： $g(a^t, t, o^t) \mapsto \hat{a}^{t-1}$ 。损失函数现在可以定义为：

$$\mathcal{L}_{\text{CSA}}(\theta) = \text{MSE}(f(a^t, t, o^t), f(\hat{a}^{t-1}, t-1, o^{t-1})) \quad (2)$$

与之前的方法不同，CSA 的推理阶段不是从高斯噪声开始，也不会将噪声注入用户样本。给定用户的动作 a^u ，我们假设 $a^u \sim \mathcal{N}(a, \sigma^t)$ ，其中 t 是一个超参数，决定了用户动作对应的 ODE 流程的步骤（图 ??）。我们定义了 $\alpha = \frac{t}{T}$ ，它控制假设的噪声量，通过这可以调整生成动作的保真度和一致性之间的平衡。使用预训练的前向模型，我们可以基于用户动作 a^u 和当前状态 s ， $\Phi(a^u, s) \mapsto \hat{s}_n$ 获得下一个状态估计，提供短期的用户意图。过程 $\{s, \hat{s}_n\}$ 到 $\{\text{cond}_1, \text{cond}_2\}$ 作为 CSA 模型的条件。然后我们将使用一步采样器将总噪声分成 T 段，选择符合 a^u 的噪声步骤 t 和噪声水平 σ^t 。最后应用 CM noiser $f(a^u, t, o^t) \mapsto \hat{a}^0$ 来完成一步去噪。我们称仅以 $\{\text{cond}_1\}$ 为条件的模型为 CSA，以 $\{\text{cond}_1, \text{cond}_2\}$ 为条件的变体为 $\text{CSA}^\dagger$ 。我们展示了 $\text{CSA}^\dagger$ 保持了用户的意图，因此扩大了有效推理的“最佳范围”。

3 实验

我们在一些连续控制任务的模拟以及真实机器人实验中评估了我们提出的 CSA 模型的性能。

3.1 评估任务

我们考虑以下四个连续控制领域作为将 CSA 与当代基于 DDPM 的基线进行比较的方法。附录 4.4 提供了进一步的实验细节。

(a) 月球着陆器：月球着陆器环境（图 4a）是一个二维、连续控制任务，改编自 Open AI Gym [38]，要求将航天器降落在一个固定的着陆垫上。当航天器安全着陆、坠毁、偏离航道或经过 1000 步后超时，回合结束。

(b) 插销插入：插销插入（图 4b）要求机械臂将一个长 10 厘米、半径 2 厘米的插销插入一个只有 1 厘米间隙的孔中。在每个回合开始时，插销和目标箱的姿态都是随机的。当插销尖端进入孔超过 1.5 厘米时，即视为成功；否则，回合将在 200 步后终止。

(c) 充电器插入：充电器插入（图 4c）进一步缩小了公差：双插脚充电器必须在只有 0.5mm 间隙的情况下滑入其插座。每个回合中都会随机化充电器和插座的态度，智能体同样使用紧凑的运动学和视觉输入来控制末端执行器。如果插头在距离与目标姿态 5mm 和 0.2 弧度

内插入，则该回合视为成功。当插入成功时，有强烈撞击发生时，或在经过 300 步后超时，回合会终止。

(d) 实际木钉插入：实际木钉插入（图 4d）是通过安装有 Robotiq 三指夹持器的 UR5 机械臂进行的。任务包括将一个红色方形木钉或一个蓝色圆柱形木钉插入到对应的孔中，分别具有 5 mm 和 4.5 mm 的间隙公差。

3.2 数据收集

训练辅助策略需要一个专家操作员来提供专家过渡 (s_t, a_t, s_{t+1}) 。我们使用软演员-评论家 (SAC) [39] 算法来训练月球着陆器和插销插入的专家策略，并结合课程学习 (CL) 的近端策略优化 (PPO) [40] 来训练充电器插入的专家，将成功检查放宽到 1.8 厘米，然后逐渐缩小到 5 毫米，以获得此高精度任务的专家 [41]。在获取专家策略后，我们应用拒绝采样仅从成功的情节中收集转换。所有三个模拟实验，无论困难程度如何，都使用 200 K 次转换进行训练。对于真实的插销插入任务，通过使用 Meta Quest 3 VR 控制器的经验丰富的人工操作员收集演示。我们以 (s_t, a_t, s_{t+1}) 的相同形式收集了 180 次演示，总共 62 K 次转换。此过程由 2 位操作员在 1 小时内完成。

3.3 代理飞行员

虽然 CSA 在训练中不需要访问一个真实或代理飞行员，但我们使用代理飞行员来扩大评估的数量。基于之前的工作 [7, 8, 1]，我们定义了四种不同的代理：noisy、laggy、noised 和 slow，作为专家策略 π 的损坏版本。

$$\begin{aligned} \text{Noisy}(s_t, g) &= \begin{cases} a_t^e, & \text{if } p \geq \epsilon \\ a_t^r, & \text{if } p < \epsilon \end{cases} & \text{Laggy}(s_t, g) &= \begin{cases} a_t^e, & \text{if } p \geq \epsilon \\ a_{t-1}^e, & \text{if } p < \epsilon \end{cases} \\ \text{Noised}(s_t, g) &= a_t^e + \mathcal{N}(0, \epsilon) & \text{Slow}(s_t, g) &= (1 - \epsilon) \cdot a_t^e \end{aligned}$$

，其中 $\epsilon \in [0, 1]$ 是决定损坏程度的缺陷参数，脚标 t 是时间步（在情节中）， a_t^e 是专家动作， a_t^r 是随机动作， s_t 是状态， g 指的是目标。我们在不同的缺陷水平 ϵ 下评估了四个代理，每个代理有 10 个随机种子和 30 次回合。我们在附录 4.2 表 4 中提供了参数 ϵ 的值。

3.4 评估结果

模拟结果：鉴于我们的方法是目标排除的、状态条件的共享控制模型，我们与基于 SDE 的 DDPM 的基线 [1] 进行比较，采用他们的前向扩散比例 α 来权衡保真度和一致性。图 5 和 6 显示，在低维的 Lunar Lander 任务中，CSA 达到了与基线相当的性能，而在高维的 Peg 插入任务中，CSA 显著优于它——在噪音环境中，DDPM 策略的收益不到 10 %。

在高精度的充电器插头插入任务中，我们在十个噪声调度 ($\beta_{\max} \sim \text{Unif}[0.01, 0.25]$) 上测试了 DDPM 基线，结果没有一次成功运行，这凸显了其对调度调节的极高敏感性以及相关的计算成本。相比之下，CSA 在所有任务中以单一的超参数设置实现了稳健的成功，消除了对每个任务的噪声调节，并节省了大量时间。


如 ?? 节详细说明，CSA[†] 变体通过依赖预测的下一个状态，在较大的 α 处进一步保留用户意图。在图 5b，5c 和图 6b，6c 中，其成功率在超过最佳噪声比后保持不变，从而避免了在推理期间仔细选择噪声比的需要。

真实机器人结果：我们通过真人用户实验在真实插销实验环境中测量我们的辅助策略的有效性。我们招募了 10 名参与者（6 人自认男性，3 人为女性，1 人不愿透露，平均年龄为 25.9 岁）。¹ 我们向参与者展示了两个未标识的副驾驶系统，一个是我们的辅助策略 CSA[†]，另一个是直接遥控操作（即，没有辅助）。²


在实验开始时，我们让参与者分别与两个副驾驶进行两次试验练习。在随后的测试阶段，每位参与者控制机器人手臂，用随机选择的一个副驾驶各试三次插入方形钉和圆柱钉，然后

¹没有参与者是本文的合著者或以其他方式参与了这项研究。


²在真实机器人实验中没有将 DDPM 作为基准是因为其性能对超参数极其敏感；尽管进行了广泛的调整，我们仍无法找到能够在此任务中实现稳定收敛的设置。



(a) DDPM 策略




(b) CSA




(c) CSA[†]


Figure 5: 月球着陆器噪声模拟结果



(a) DDPM 策略



(b) CSA



(c) CSA[†]

Figure 6: 桩插入噪声模拟结果

用另一个副驾驶重复此过程。参与者通过手持的 Quest3 VR 控制器提供用户动作 a^u ，并仅通过侧装摄像头的画面观看场景，从而去除了正常的双眼深度提示。任何超过 60 秒限制或因过大的接触力触发紧急停止的试验均被标记为失败。

我们考虑了助理策略 CSA[†] 的定量和定性表现。定量方面，表 3 比较了有无我们的助理策略情况下的平均成功率和平均完成时间，结果显示为参与者提供我们的助理策略提高了他们的成功率并减少了完成时间。定性结果详见附录 4.5。

我们提出了 CSA，这是一种无模型的共享自治框架，它利用基于 ODE 的提取扩散模型与部分扩散，实现一步去噪的协同控制。在没有任何明确目标预测的情况下，CSA 仅依赖于不包含目标的专家示范来“回闪”每个用户动作到其最近的专家分布——确保了平滑的轨迹校正，同时忠实地保留了用户的意图。在大量实验中，CSA 在经典的二维难控基准（例如月球着陆器）上表现优于先前的方法，并在高维、高精度任务中（如充电器插头插入）提

Actor	Method	Success Rate (%) $\uparrow$	Crash Rate (%) $\downarrow$	NFE	Inference Time (ms) $\downarrow$
Laggy	Surrogate	40.00 $\pm$ 4.16	52.66 $\pm$ 4.92	—	—
	DDPM	75.67 $\pm$ 9.30	14.67 $\pm$ 6.32	24	13.62 $\pm$ 0.22
	CSA	87.67 $\pm$ 5.89	6.67 $\pm$ 4.16	1	0.92 $\pm$ 0.04
	CSA [†]	91.00 $\pm$ 3.87	5.00 $\pm$ 3.24	1	1.22 $\pm$ 0.30
Noisy	Surrogate	26.00 $\pm$ 6.44	6.67 $\pm$ 3.85	—	—
	DDPM	55.67 $\pm$ 7.86	4.67 $\pm$ 3.58	24	17.67 $\pm$ 1.49
	CSA	85.00 $\pm$ 8.05	2.67 $\pm$ 3.44	1	1.79 $\pm$ 0.24
	CSA [†]	89.00 $\pm$ 4.17	2.33 $\pm$ 2.25	1	2.03 $\pm$ 0.35
Noised	Surrogate	16.67 $\pm$ 8.46	0.00 $\pm$ 0.00	—	—
	DDPM	73.67 $\pm$ 10.71	10.43 $\pm$ 2.11	24	18.60 $\pm$ 1.51
	CSA	94.33 $\pm$ 4.46	0.00 $\pm$ 0.00	1	1.94 $\pm$ 0.25
	CSA [†]	94.67 $\pm$ 3.91	0.67 $\pm$ 1.41	1	1.82 $\pm$ 0.59
Slow	Surrogate	75.33 $\pm$ 7.57	18.33 $\pm$ 5.93	—	—
	DDPM	92.67 $\pm$ 4.09	3.00 $\pm$ 2.92	14	10.44 $\pm$ 0.07
	CSA	80.33 $\pm$ 5.32	11.33 $\pm$ 6.13	1	1.72 $\pm$ 0.27
	CSA [†]	79.00 $\pm$ 6.10	12.67 $\pm$ 6.81	1	1.77 $\pm$ 0.24

Table 1: 月球着陆器性能

Pilot	Copilot	Peg Insertion			Charger Plug Insertion		
		Success Rate(%) $\uparrow$	NFE	Inference Time(ms) $\downarrow$	Success Rate(%) $\uparrow$	NFE	Inference Time(ms) $\downarrow$
Laggy	None	39.33 $\pm$ 10.16	—	—	22.00 $\pm$ 7.57	—	—
	DDPM	55.00 $\pm$ 8.35	9	5.25 $\pm$ 0.42	0.00 $\pm$ 0.00	—	—
	CSA	56.33 $\pm$ 12.22	1	1.00 $\pm$ 0.19	29.00 $\pm$ 10.89	1	1.35 $\pm$ 0.37
	CSA [†]	45.67 $\pm$ 8.61	1	1.02 $\pm$ 0.16	22.33 $\pm$ 6.30	1	1.01 $\pm$ 0.06
Noisy	None	24.00 $\pm$ 4.66	—	—	17.00 $\pm$ 4.57	—	—
	DDPM	28.33 $\pm$ 7.07	4	2.72 $\pm$ 0.59	0.00 $\pm$ 0.00	—	—
	CSA	71.67 $\pm$ 8.92	1	1.04 $\pm$ 0.15	36.67 $\pm$ 8.31	1	1.34 $\pm$ 0.41
	CSA [†]	69.33 $\pm$ 7.83	1	1.18 $\pm$ 0.31	56.67 $\pm$ 5.67	1	1.04 $\pm$ 0.12
Noised	None	20.00 $\pm$ 7.03	—	—	31.67 $\pm$ 9.06	—	—
	DDPM	40.00 $\pm$ 8.16	9	5.12 $\pm$ 0.15	0.00 $\pm$ 0.00	—	—
	CSA	69.00 $\pm$ 8.90	1	1.18 $\pm$ 0.15	70.00 $\pm$ 8.89	1	1.59 $\pm$ 0.33
	CSA [†]	58.00 $\pm$ 8.34	1	1.29 $\pm$ 0.20	60.67 $\pm$ 7.50	1	1.71 $\pm$ 0.40
Slow	None	29.67 $\pm$ 8.38	—	—	29.33 $\pm$ 5.40	—	—
	DDPM	29.33 $\pm$ 4.10	—	—	0.00 $\pm$ 0.00	—	—
	CSA	59.67 $\pm$ 12.32	1	0.99 $\pm$ 0.18	36.33 $\pm$ 10.12	1	1.25 $\pm$ 0.36
	CSA [†]	35.00 $\pm$ 7.58	1	1.09 $\pm$ 0.22	50.33 $\pm$ 8.23	1	1.25 $\pm$ 0.37

Table 2: 插销插入和充电器插入

Copilot	Square Peg		Cylinder Peg		Overall	
	Success Rate (%) $\uparrow$	Time (s) $\downarrow$	Success Rate (%) $\uparrow$	Time (s) $\downarrow$	Success Rate (%) $\uparrow$	Time (s) $\downarrow$
None	60.0	25.9	73.3	30.4	66.7	28.4
CSA [†] (ours)	73.3	22.6	93.3	24.3	83.3	24.1

Table 3: 真实插销插入性能有和没有我们的 CSA[†] 助理。

供了强有力的辅助——在这些环境中过去的方法由于数据有限、超参数敏感性或推理速度缓慢而表现不佳。此外，我们对 CSA[†] 变体的研究揭示了隐式短期意图建模是如何支持稳健的保真度维护的。这些结果强调了一种基于一致性模型的共享自治在实时、目标无关的复杂控制领域中提供帮助潜力。

虽然 CSA 表现出强大的性能和实时响应能力，但有几个领域需要深入探索。首先，我们的下一状态预测变体 $CSA^\dagger$ 可能会在代理噪声水平 (ϵ) 增大时劣化 (≥ 0.5)。在这种情况下，代理的输出可能偏离合乎理性的人的行为，导致预测价值不大。解决这种情况可能需要更强大的代理模型，能够在噪声环境中保持真实性，或者需要采用自适应噪声校准策略。

同样重要的是了解示范数据的选择如何影响辅助性能。训练在“干净的”、低方差的专家轨迹上可能会产生极为精确的校正，但也有可能拒绝安全但非常规的用户运动；反之，接受更广泛、更高方差的数据集可能提高灵活性，但使得区分核心专家动作和无害的探索性动作变得更加困难。分析这种权衡并开发自动识别和优先处理“因果”专家模式的方法，是未来研究中的一个有前景的方向。

最后，这两个线程在推理时对动态调整助力强度 (α) 的挑战上汇聚。一个理想的系统能够评估用户每个动作的专业水平——也许通过置信度指标或学习的意图分类器——并相应地调整 α ，在需要时提供更强的修正，而在用户表现出能力时退后一步。我们认为，开发此类具有情境感知的实时调节机制是一个极具前景的方向，以增强基于一致性模型的共享自治系统的性能和用户信任。

References

- [1] T. Yoneda, L. Sun, G. Yang, B. Stadie, and M. Walter. To the noise and back: Diffusion for shared autonomy. arXiv preprint arXiv:2302.12244, 2023.
- [2] C. Costen, M. Rigter, B. Lacerda, and N. Hawes. Mixed observability MDPs for shared autonomy with uncertain human behaviour. In Proceedings of the International Joint Conference on Artificial Intelligence (IJCAI), 2021.
- [3] P. Aigner and B. McCarragher. Human integration into robot control utilising potential fields. In Proceedings of the IEEE International Conference on Robotics and Automation (ICRA), pages 291–296, 1997. doi:10.1109/ROBOT.1997.620053.
- [4] R. C. Goertz. Manipulators used for handling radioactive materials. Human Factors in Technology, pages 425–443, 1963.
- [5] D. A. Abbink, T. Carlson, M. Mulder, J. C. F. de Winter, F. Aminravan, T. L. Gibo, and E. R. Boer. A topology of shared control systems—finding common ground in diversity. IEEE Transactions on Human-Machine Systems, 48(5):509–525, 2018. doi:10.1109/THMS.2018.2791570.
- [6] B. McMahan, Z. M. Peng, B. Zhou, and J. Kao. Shared autonomy with IDA: Interventional diffusion assistance. In Advances in Neural Information Processing Systems (NeurIPS), pages 128330–128354, 2024.
- [7] S. Reddy, A. D. Dragan, and S. Levine. Shared autonomy via deep reinforcement learning. arXiv preprint arXiv:1802.01744, 2018.
- [8] C. Schaff and M. R. Walter. Residual policy learning for shared autonomy. arXiv preprint arXiv:2004.05097, 2020.
- [9] M. Ghorbel, J. Pineau, R. Gourdeau, S. Javdani, and S. Srinivasa. A decision-theoretic approach for the collaborative control of a smart wheelchair. International Journal of Social Robotics, 10:131–145, 2018.
- [10] S. Schröer, I. Killmann, B. Frank, M. Völker, L. Fiederer, T. Ball, and W. Burgard. An autonomous robotic assistant for drinking. In Proceedings of the IEEE International Conference on Robotics and Automation (ICRA), pages 6482–6487, 2015.
- [11] A. Phung, G. Billings, A. F. Daniele, M. R. Walter, and R. Camilli. Enhancing scientific exploration of the deep sea through shared autonomy in remote manipulation. Science Robotics, 8(81), 2023.

- [12] K. Muelling, A. Venkatraman, J.-S. Valois, J. E. Downey, J. Weiss, S. Javdani, M. Hebert, A. B. Schwartz, J. L. Collinger, and J. A. Bagnell. Autonomy infused teleoperation with application to brain computer interface controlled manipulation. *Autonomous Robots*, 41:1401–1422, 2017.
- [13] S. Javdani, S. S. Srinivasa, and J. A. Bagnell. Shared autonomy via hindsight optimization. In *Proceedings of Robotics: Science and Systems (RSS)*, pages 10–15607, 2015.
- [14] C. Pérez-D’Arpino and J. A. Shah. Fast target prediction of human reaching motion for cooperative human-robot manipulation tasks using time series classification. In *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, pages 6175–6182, 2015.
- [15] A. D. Dragan and S. S. Srinivasa. A policy-blending formalism for shared control. *International Journal of Robotics Research*, 32(7):790–805, 2013.
- [16] J. Ho, A. Jain, and P. Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 6840–6851, 2020.
- [17] J. Song, C. Meng, and S. Ermon. Denoising diffusion implicit models. *arXiv preprint arXiv:2010.02502*, 2020.
- [18] T. Karras, M. Aittala, T. Aila, and S. Laine. Elucidating the design space of diffusion-based generative models. 2022.
- [19] Z. Kong, W. Ping, J. Huang, K. Zhao, and B. Catanzaro. DiffWave: A versatile diffusion model for audio synthesis. *arXiv preprint arXiv:2009.09761*, 2021.
- [20] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer. High-resolution image synthesis with latent diffusion models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 10684–10695, 2022.
- [21] L. Ruan, Y. Ma, H. Yang, H. He, B. Liu, J. Fu, N. J. Yuan, Q. Jin, and B. Guo. MM-Diffusion: Learning multi-modal diffusion models for joint audio and video generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 10219–10228, 2023.
- [22] S. Sheynin, A. Polyak, U. Singer, Y. Kirstain, A. Zohar, O. Ashual, D. Parikh, and Y. Taigman. Emu Edit: Precise image editing via recognition and generation tasks. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 8871–8879, 2024.
- [23] B. Poole, A. Jain, J. T. Barron, and B. Mildenhall. DreamFusion: Text-to-3D using 2D diffusion. *arXiv preprint arXiv:2209.14988*, 2022.
- [24] Y. Xu, J. Mao, Y. Du, T. Lozano-Pérez, L. P. Kaelbling, and D. Hsu. ” set it up! ”: Functional object arrangement with compositional generative models. *arXiv preprint arXiv:2405.11928*, 2024.
- [25] C. Chi, Z. Xu, S. Feng, E. Cousineau, Y. Du, B. Burchfiel, R. Tedrake, and S. Song. Diffusion policy: Visuomotor policy learning via action diffusion. *International Journal of Robotics Research*, 2024.
- [26] J. Carvalho, A. T. Le, M. Baierl, D. Koert, and J. Peters. Motion planning diffusion: Learning and planning of robot motions with diffusion models. *arXiv preprint arXiv:2308.01557*, 2024.

- [27] Z.-H. Yin, C. Wang, L. Pineda, F. Hogan, K. Bodduluri, A. Sharma, P. Lancaster, I. Prasad, M. Kalakrishnan, J. Malik, et al. DexterityGen: Foundation controller for unprecedented dexterity. arXiv preprint arXiv:2502.04307, 2025.
- [28] Y. Song, P. Dhariwal, M. Chen, and I. Sutskever. Consistency models. arXiv preprint arXiv:2303.01469, 2023.
- [29] A. Prasad, K. Lin, J. Wu, L. Zhou, and J. Bohg. Consistency policy: Accelerated visuomotor policies via consistency distillation. In Proceedings of Robotics: Science and Systems (RSS), 2024.
- [30] C. Meng, Y. He, Y. Song, J. Song, J. Wu, J.-Y. Zhu, and S. Ermon. SDEdit: Guided image synthesis and editing with stochastic differential equations. arXiv preprint arXiv:2108.01073, 2022.
- [31] T. Debus, J. Stoll, R. D. Howe, and P. Dupont. Cooperative human and machine perception in teleoperated assembly. In Proceedings of the International Symposium on Experimental Robotics (ISER), pages 51–60, 2001.
- [32] J. Kofman, X. Wu, T. J. Luu, and S. Verma. Teleoperation of a robot manipulator using a vision-based human-robot interface. IEEE Transactions on Industrial Electronics, 52(5):1206–1219, 2005.
- [33] B. D. Argall. Modular and adaptive wheelchair automation. In Proceedings of the International Symposium on Experimental Robotics (ISER), pages 835–848, 2015.
- [34] W. Tan, D. Koleczek, S. Pradhan, N. Perello, V. Chettiar, V. Rohra, A. Rajaram, S. Srinivasan, H. S. Hossain, and Y. Chandak. On optimizing interventions in shared autonomy. In Proceedings of the National Conference on Artificial Intelligence (AAAI), pages 5341–5349, 2022.
- [35] M. Janner, Y. Du, J. Tenenbaum, and S. Levine. Planning with diffusion for flexible behavior synthesis. In Proceedings of the International Conference on Machine Learning (ICML), 2022.
- [36] C. Meng, R. Rombach, R. Gao, D. Kingma, S. Ermon, J. Ho, and T. Salimans. On distillation of guided diffusion models. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pages 14297–14306, 2023.
- [37] T. Salimans and J. Ho. Progressive distillation for fast sampling of diffusion models. arXiv preprint arXiv:2202.00512, 2022.
- [38] G. Brockman, V. Cheung, L. Pettersson, J. Schneider, J. Schulman, J. Tang, and W. Zaremba. OpenAI Gym. arXiv preprint arXiv:1606.01540, 2016.
- [39] T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In International conference on machine learning, pages 1861–1870. Pmlr, 2018.
- [40] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. Proximal policy optimization algorithms. arXiv preprint arXiv:1707.06347, 2017.
- [41] B. Tang, M. A. Lin, I. Akinola, A. Handa, G. S. Sukhatme, F. Ramos, D. Fox, and Y. Narang. Industreal: Transferring contact-rich assembly tasks from simulation to reality. arXiv preprint arXiv:2305.17110, 2023.

4 附录

4.1 初步：概率流动常微分方程

扩散模型可以被解释为前向扩散过程的反向微分方程的离散数值解算器。一个扩散模型由两个过程来表征。向前扩散过程是一个一阶马尔可夫链，它迭代地向从数据分布 $\mathbf{y} \sim p_{\text{data}}(\mathbf{y})$ 中抽取的（干净的）样本添加噪声。反向扩散过程通过逆转这个过程来从数据分布中生成样本，从而对噪声输入 $\mathbf{x}$ 进行去噪。在一般方法中，一个神经网络 $D(\cdot)$ 被训练来近似瞬时得分函数 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 作为反向过程的参数化。通过使用概率流 (PF) ODE 实例化生成过程，可以定义描述样本在时间上向前或向后演变的一般形式为 [28, 18]：

$$d\mathbf{x} = -\dot{\sigma}(t)\sigma(t)\nabla_{\mathbf{x}} \log p_t(\mathbf{x}; \sigma(t))dt, \quad (3)$$

其中 $\sigma(t)$ 是时间 t 所期望的噪声水平，并且在实践中被设置为本文采用的 EDM 模型 [18] 的 t 。在前向过程中，我们表示 $p_t(\mathbf{x}; \sigma) = p_{\text{data}} \cdot \mathcal{N}(\mathbf{0}, \sigma(t)^2 \mathbf{I})$ 。去噪器函数 $D(\mathbf{x}; \sigma)$ 旨在最小化从 $p_{\text{data}}(\mathbf{y})$ 抽取的样本 $\mathbf{y}$ 的 L^2 误差

$$\mathbb{E}_{\mathbf{y} \sim p_{\text{data}}} \mathbb{E}_{\mathbf{n} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})} \|D(\mathbf{y} + \mathbf{n}; \sigma) - \mathbf{y}\|_2^2, \quad (4)$$

其中 $\mathbf{n}$ 是噪声。 $D(\mathbf{x}; \sigma)$ 和得分函数之间的关系为

$$\nabla_{\mathbf{x}} \log p(\mathbf{x}; \sigma) = (D(\mathbf{x}; \sigma) - \mathbf{x})/\sigma^2. \quad (5)$$

如在第 2 节所述，ODE 训练目标考虑多模态情形下最近的目标分布。展开方程 4（见附录 ??），损失变为

$$\mathcal{L}(D; \mathbf{x}, \sigma) = \int_{\mathbb{R}^d} \frac{1}{Y} \sum_{i=1}^Y \mathcal{N}(\mathbf{x}; \mathbf{y}_i, \sigma^2 \mathbf{I}) \|D(\mathbf{x}; \sigma) - \mathbf{y}_i\|_2^2 d\mathbf{x} \quad (6)$$

最小化 $\mathcal{L}(D; \mathbf{x}, \sigma)$ 等价于求解一个凸优化问题，闭式解如下所示：

$$D(\mathbf{x}; \sigma) = \frac{\sum_i \mathcal{N}(\mathbf{x}; \mathbf{y}_i, \sigma^2 \mathbf{I}) \mathbf{y}_i}{\sum_i \mathcal{N}(\mathbf{x}; \mathbf{y}_i, \sigma^2 \mathbf{I})}, \quad (7)$$

上述涉及对所有可能的目标分布 $\mathbf{y}_i$ 进行 softmax 操作，这是对噪声样本 $\mathbf{x}$ 的可行性操作，因此可以保证选择最近的邻居。图 7 显示基于 SDE 的 DDPM 模型无法保证找到最近的专家，而基于 ODE 的模型在蒸馏后可以通过一步完成这一过程。




Figure 7: 一致性模型和 DDPM 在二维示例中的应用

假设我们的训练集由有限数量的样本 $\{\mathbf{y}_1, \dots, \mathbf{y}_Y\}$ 组成。这意味着 $p_{\text{data}}(\mathbf{x})$ 由狄拉克分布的混合表示：

这使我们也能够以封闭形式表达 $p(\mathbf{x}; \sigma)$,

$$\begin{aligned}
p(\mathbf{x}; \sigma) &= p_{\text{data}} * \mathcal{N}(\mathbf{0}, \sigma(t)^2 \mathbf{I}) \\
&= \int_{\mathbb{R}^d} p_{\text{data}}(\mathbf{x}_0) \mathcal{N}(\mathbf{x}; \mathbf{x}_0, \sigma^2 \mathbf{I}) d\mathbf{x}_0 \\
&= \int_{\mathbb{R}^d} \left[\frac{1}{Y} \sum_{i=1}^Y \delta(\mathbf{x}_0 - \mathbf{y}_i) \right] \mathcal{N}(\mathbf{x}; \mathbf{x}_0, \sigma^2 \mathbf{I}) d\mathbf{x}_0 \\
&= \frac{1}{Y} \sum_{i=1}^Y \int_{\mathbb{R}^d} \mathcal{N}(\mathbf{x}; \mathbf{x}_0, \sigma^2 \mathbf{I}) \delta(\mathbf{x}_0 - \mathbf{y}_i) d\mathbf{x}_0 \\
&= \frac{1}{Y} \sum_{i=1}^Y \mathcal{N}(\mathbf{x}; \mathbf{y}_i, \sigma^2 \mathbf{I}) .
\end{aligned}$$

现在让我们考虑公式 4 的去噪评分匹配损失。通过展开期望, 我们可以将公式重写为关于噪声样本 $\mathbf{x}$ 的积分:

$$\begin{aligned}
\mathcal{L}(D; \sigma) &= \mathbb{E}_{\mathbf{y} \sim p_{\text{data}}} \mathbb{E}_{\mathbf{n} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})} \|D(\mathbf{y} + \mathbf{n}; \sigma) - \mathbf{y}\|_2^2 \\
&= \mathbb{E}_{\mathbf{y} \sim p_{\text{data}}} \mathbb{E}_{\mathbf{x} \sim \mathcal{N}(\mathbf{y}, \sigma^2 \mathbf{I})} \|D(\mathbf{x}; \sigma) - \mathbf{y}\|_2^2 \\
&= \mathbb{E}_{\mathbf{y} \sim p_{\text{data}}} \int_{\mathbb{R}^d} \mathcal{N}(\mathbf{x}; \mathbf{y}, \sigma^2 \mathbf{I}) \|D(\mathbf{x}; \sigma) - \mathbf{y}\|_2^2 d\mathbf{x} \\
&= \frac{1}{Y} \sum_{i=1}^Y \int_{\mathbb{R}^d} \mathcal{N}(\mathbf{x}; \mathbf{y}_i, \sigma^2 \mathbf{I}) \|D(\mathbf{x}; \sigma) - \mathbf{y}_i\|_2^2 d\mathbf{x} \\
&= \underbrace{\int_{\mathbb{R}^d} \frac{1}{Y} \sum_{i=1}^Y \mathcal{N}(\mathbf{x}; \mathbf{y}_i, \sigma^2 \mathbf{I}) \|D(\mathbf{x}; \sigma) - \mathbf{y}_i\|_2^2 d\mathbf{x}}_{=: \mathcal{L}(D; \mathbf{x}, \sigma)} .
\end{aligned}$$

证明是采用自 EDM 附录 [18] 。

4.2 代理超参数选择和性能

在图 8 中, 我们可以看到对于噪声替代, 当 $\epsilon = 0.0$ 时, 替代实际上是专家, 而当 $\epsilon = 0.45$ (图 8a) 时, 成功率显著下降到 20 %, 因此我们选择 $\epsilon^{\text{noised}} = 0.45$ 作为月球着陆环境。同样地, 我们可以为插针和充电器插入选择相同的方法, 表 4 显示了我们使用的超参数 ϵ 。

Table 4: 替代缺陷参数

Environment	ϵ^{laggy}	ϵ^{noisy}	ϵ^{noised}	ϵ^{slow}
Lunar Lander	0.85	0.30	0.45	0.47
Peg Insertion	0.80	0.15	0.20	0.65
Charge Plug Insertion	0.60	0.15	0.10	0.40

4.3 EDM 详细信息

一旦噪声计划 $\{\sigma_t\}_{t=0}^{T-1}$ 确定, EDM 模型便被完全指定。该计划将噪声标准差 σ_t 分配给每个离散扩散步骤 t 。在整篇论文中, 我们采用 Karras et al. [18] 的默认超参数:

$$\sigma_{\min} = 0.002, \quad \sigma_{\max} = 80.0, \quad \sigma_{\text{data}} = 0.5, \quad \rho = 7.$$

T 噪声水平和索引 $t \in \{0, \dots, T-1\}$ 的情况下, 进度是

$$\sigma^t = \left(\sigma_{\max}^{1/\rho} + \frac{t}{T-1} (\sigma_{\min}^{1/\rho} - \sigma_{\max}^{1/\rho}) \right)^\rho. \quad (\text{A.1})$$




Figure 8: 月球着陆器在不同缺陷参数 ϵ 下的替代性能

在任何噪声水平 σ^t 下，EDM 使用

$$\begin{aligned}
 c_{\text{in}}^t &= \frac{1}{\sqrt{(\sigma^t)^2 + \sigma_{\text{data}}^2}}, \\
 [4pt]c_{\text{skip}}^t &= \frac{\sigma_{\text{data}}^2}{(\sigma^t)^2 + \sigma_{\text{data}}^2}, \\
 [4pt]c_{\text{out}}^t &= \frac{\sigma^t \sigma_{\text{data}}}{\sqrt{(\sigma^t)^2 + \sigma_{\text{data}}^2}}.
 \end{aligned} \tag{A.2}$$

重新缩放网络输入、跳跃连接和输出

这些系数在 σ_{max} 和 σ_{min} 之间宽广的动态范围内稳定了训练和采样。

每当一个训练批次需要噪声水平时，我们从时间表中均匀抽取索引 t ：

$$t \sim \mathcal{U}\{0, \dots, T-1\}, \quad \sigma \leftarrow \sigma_t.$$

4.4 实验细节

(a) Lunar Lander : Lunar Lander(图 4a) 是一个来自 OpenAI Gym 的 2D 连续控制环境，目标是将飞船降落在指定的降落平台上。动作空间控制作用于左右引擎的推力；例如，为了向左转，智能体需要对右引擎施加比左引擎稍大的推力。相比于人类的自然直觉（例如，向左推即向左移动），这种间接控制策略是不直观的，使得任务特别具有挑战性。状态空间包括飞船的位置、角度、线性和角速度、每条腿的地面接触指示器以及降落平台的位置（后者仅提供给飞行员）。在飞船成功降落并变为静止、坠毁、飞出边界或达到 1000 步超时，回合终止。

(b) 钉插入：钉插入（图 4b）是一个来自 ManiSkill 的连续控制环境，涉及一个机器人手臂负责将橙白色钉的橙色末端插入一个盒子的孔中。钉的固定半长度为 10 厘米，半径为 2 厘米，而盒子孔的半径提供 1 厘米的间隙。在每一集的开始，钉子和盒子的位置和方向会在平坦的桌面上随机化。动作涉及连续的末端执行器运动。状态包括机器人关节位置和速度、末端执行器姿态、钉子的姿态和尺寸以及孔的姿态和半径。当钉子的白色末端距离孔中心在 1.5 厘米以内时，任务被认为成功。成功、违反边界限制或达到 200 步限制时，剧集结束。

(c) 充电器插头插入：充电器插头插入（图 4c）是插销插入的高级版本，其中机器人手臂必须拾取充电器并将其插入插座。充电器具有固定尺寸的底座和双插销设计，插入间隙为 0.5 毫米。在每个回合开始时，充电器和插座在桌面上的 XY 位置和方向是随机的。动作控制机器人的末端执行器。状态包括机器人的关节位置和速度、末端执行器的姿态、充电器的




Figure 9: 真人参与者在实际插销任务中的定性调查结果

Environment	State Dimension	Action Dimension
Lunar Lander (Fig. 4a)	8	2
Peg Insertion (Fig. 4b)	35	8
Charger Plug Insertion (Fig. 4c)	32	8
Real Peg Insertion (Fig. 4d)	9	3

Table 5: 每个环境的状态和动作维度

姿态、插座姿态以及目标姿态。当充电器在 5 毫米的位置公差和 0.2 弧度的角度公差内被完全插入时，即视为成功。回合在成功、违反边界或达到 300 步限制时结束。

(d) 实际销插入：实际销插入（图 4d）由配备 Robotiq 三指夹持器的 UR5 机器人手臂执行。该任务涉及将红色方形销或蓝色圆柱销插入其对应的孔中，间隙公差分别为 5 mm 和 4.5 mm。状态 s_t 包括末端执行器的当前姿态和腕部安装的 FT-300 力/力矩传感器的测力读数。动作 a_t 是目标末端执行器的位置。

4.5 人类参与者定性调查结果

在一项定性调查中，我们要求参与者使用五点 Likert 量表对每个助手在“有用性”、“一致性”、“响应性”、“协作性”和“可信赖性”方面进行评分。他们还被问及更喜欢哪一个助手。为避免偏见，我们没有揭示哪个系统是我们的辅助政策；调查中只是将它们标记为“政策 A”和“政策 B”。

如图 9 所示，参与者认为我们的辅助副驾驶在帮助性、协作性和可信度方面评分较高，大多数人总体上更倾向于它。我们还收到了诸如“从用户的角度来看，在策略 B（我们的辅助策略）下操控和运动更流畅”，“在使用 B 插入过程中感觉得到了帮助”，以及“策略 A（直接远程操作）特别是在向下移动时很容易超调”这样的评论。